



1-1. AI&기계학습 기초

목차

- 1. AI와 ML은 무엇인가?
 - 1. AI와 ML의 개념
 - 1-1. AI 및 ML의 정의
 - 2. 데이터와 학습의 이해
 - 2-1 데이터 구성요소 (Feature/Label)
 - 2-2 ML 예시 : 실생활 예시
 - 3. 단일 피쳐 기반 학습
 - 3-1 1D 피쳐 기반 학습
 - 3-2. 1D 피쳐 기반 학습 : 무엇을 학습하는가?
 - 3-3. 모델과 가설 공간
 - 3-4. 데이터, 모델, 가설 공간
 - 3-5 학습이란?
 - 4. 복수 피쳐 기반 학습
 - 4-1. ML 예시: 2D 피쳐 기반 학습
 - 4-2. ML 예시: 2D 피쳐 기반 학습
 - 4-3. 일반적 용어 정리 및 모델 가정
 - 4-4. 왜 $f(X)$ 를 학습하는가?
- 2. 지도학습은 무엇인가?
 - 1. 지도학습의 개념
 - 1-1. 지도학습(supervised learning)이란?
 - 1-2. 지도학습 용어
 - 2. 회귀(Regression)
 - 2-1. 회귀(Regression) 문제
 - 2-2. 회귀 오류:평균제곱오차(MSE)
 - 2-3. 회귀 설명력: R^2 (결정계수)
 - 3. 분류(Classfication)
 - 3-1. 분류(Classfication) 문제
 - 3-2. 분류 정확도(Accuracy)
 - 3-3. 혼동행렬(Confusion Matrix)
 - 3-4. 정밀도, 재현율, F1-score
 - 4. 학습의 목적
 - 4-1. 학습의 목적은 테스트 예측(일반화)
 - 4-2. 오버피팅(overfitting)이란?
 - 4-3. 오버피팅에 대한 오해
 - 4-4. 오버피팅 vs 언더피팅 (균형잡기)
- 3. 교차검증(Cross-Validation)
 - 1. 테스트 성능 평가
 - 1-1. 훈련 성능 != 테스트 성능
 - 1-2. 언더피팅, 오버피팅 곡선
 - 1-3. 예측 오류를 추정하는 방법
 - 1-4. 재표본화(resampling)를 통한 테스트 오차 추정
 - 2. 검증셋(validation set) 접근
 - 2-1. 검증셋(hold-out) 방법
 - 2-2. 검증(Validation) 절차
 - 2-3. 예: 자동차 데이터
 - 2-4. 검증셋 접근의 한계
 - 3. K-겹 교차검증(K-fild Cross-Validation)
 - 3-1. K-겹 교차검증(K-fold Cross-V)
 - 3-2. K-겹 교차검증 단계
 - 3-3. K-겹 교차검증 오류 계산
 - 3-4. Leave-One-Out 교차검증
 - 3-5. Leave-One-Out 교차검증 vs 10겹 교차검증
 - 3-6 시뮬레이션: 참/추정 테스트 MSE
 - 4. 교차검증 시 주의점

4-1. 옳은 CV vs 잘못된 CV

4. 비지도 학습은 무엇인가?

1. 비지도 학습

1-1. 비지도학습이란?

1-2. 비지도vs지도, 그리고 클러스터링

2. 클러스터링

2-1. 클러스터링(Clustering)이란?

2-3. 두 가지 대표 클러스터링 기법

3. K-means 클러스터링

3-1. K-means 클러스터링

3-2. K-means의 표기(군집 집합)

3-3. K-means의 핵심 아이디어

3-4. K-means 알고리즘

3-5. K-means 알고리즘 단계별 진행

3-6. 다른 초기 값의 영향

4. 계층적 군집(Hierarchical Clustering)

4-1. 계층적 군집(Hierarchical Clustering)

4-2. 계층적 군집 결과 예시

4-3. 계층적 군집 알고리즘(상향식)

4-4. 계층적 군집 병합 진행 예

4-5. 링크(link) 유형

4-6. 링크에 따라 결과가 달라진다.

5. 클러스터링 시 주의점

5-1. 클러스터링 체크리스트

1. AI와 ML은 무엇인가?

학습 목표

- AI와 ML의 정의 및 관계를 학습한다.
- 데이터 (feature 및 label), 가설공간, 모델(model)의 개념을 학습한다.
- 학습 (learning)의 정의를 학습한다.

학습개요(오버뷰)

AI와 머신러닝이 우리 삶에 미치는 영향

- 유튜브는 어떻게 내 취향을 맞추까? 이메일은 어떻게 스팸/정상을 가려낼까?
→ 사람이 모든 규칙을 미리 코딩하지 않아도, 데이터에서 규칙을 학습해 성능을 향상한다.

1. AI와 ML의 개념

1-1. AI 및 ML의 정의


- AI : 주어진 환경/데이터를 인지,학습,추론을 통해 목표 달성을 하도록 예측, 행동 선택, 계획하는 시스템
- ML : AI 범주 내에서 데이터로부터 학습하여 목적을 달성하는 접근 방법론

- ML 의 예

- 언어 모델(언어이해/생성)
- 추천 시스템(선호 추정-의사결정)
- 자율주행(인지-판단-제어)
-

- [참고] ML이 아닌 AI 시스템의 예

- 규칙 기반 시스템
- 휴리스틱 기반 (최적화) 알고리즘



2. 데이터와 학습의 이해

2-1 데이터 구성요소 (Feature/Label)

- 데이터가 중요한가?
 - 머신 러닝은 규칙을 직접 코딩하지 않고, 데이터에서 규칙을 학습
 - 데이터(feature, label)의 분포와 관계가 머신러닝의 학습 결과를 결정
- Feature (피쳐, 특성)
 - 모델이 예측에 사용하는 정보
 - 판단의 근거, 단서가 된다.
- Label (라벨, 목표값)
 - 모델이 예측하려는 정답
 - 학습의 목표


2-2 ML 예시 : 실생활 예시

- 예시1 유튜브 추천
 - feature : 각 영상들의 정보, 사용자 정보
 - label : 영상에 대한 사용자 피드백 (좋댓구알)
- 예시2 스팸메일 분류
 - feature : 메일 제목, 발신자, 단어 빈도
 - label : 스팸 / 정상

3. 단일 피쳐 기반 학습

3-1 1D 피쳐 기반 학습

- 1D 피쳐 기반 학습(단일 피쳐 학습)이란?
 - 1D = 1차원
 - Feature 가 하나일 때 머신러닝이 학습하는 가장 단순한 형태



Income_i = $\boxed{f^*}$ (Years of Education_i) + $\boxed{\epsilon_i}$

• 데이터셋 D: 30명의 Years of Education (피쳐)와 Income (라벨) 쌍

• $D = \{(\text{Years of Education}_i, \text{Income}_i)\}_{i=1}^{30}$

- Income_i = f*(Years of Education_i) + ε_i
 - 데이터셋 D: 30명의 Years of Education (피쳐)와 Income (라벨) 쌍
 - $D = \{(\text{Years of Education}_i, \text{Income}_i)\}_{i=1}^{30}$


- 미지의 참 함수(f*)
 - Feature와 Label 사이의 실제 평균 관계
 - 직접 관측 불가
 - 오차가 포함된 데이터(점)만 관측 가능

- 측정 오차(ε)
 - 데이터에는 주로 측정 오차가 섞여있음
 - 원인 : 측정 기기의 한계, 환경적 요인등
 - 따라서, 데이터 = 참 함수 + 오차(f* + ε)


- 질문 : 피쳐와 라벨의 관계를 잘 나타낸 함수 f 는 무엇일까?
- 답변 ; 하나로 딱 정해지지 않는다.

3-2. 1D 피쳐 기반 학습 : 무엇을 학습하는가?

- 피쳐와 라벨의 관계를 잘 나타내는 함수 f 는 없을까?
 - 데이터를 설명하는 여러 함수 후보가 존재
 - 어떤 함수가 '가장 잘 맞는지' 학습해야함




3-3. 모델과 가설 공간



- 학습 (learning)
 - 입력(feature) → 출력(label) 관계를 찾는 과정
 - 평균 관계를 하나의 함수로 표현할 수 있음
 - 하지만 관계를 표현할 수 있는 함수는 무수히 많음
- 가설공간 (Hypothesis Space)
 - 관계를 표현할 수 있는 모든 후보 함수들의 모음
 - 피쳐 공간과 라벨 공간 위에서 정의된 함수들의 집합 F


- 모델 (model)
 - 가설 공간 F에 속한 특정 함수 f

3-4. 데이터, 모델, 가설 공간



3-5 학습이란?


- 학습
 - 주어진 데이터와 성능척도를 바탕으로 가설공간 F의 후보들 중 최적의 모델을 선택하는 과정
 - 데이터 D → 가설공간 F → 선택된 모델 f



4. 복수 피쳐 기반 학습


4-1. ML 예시: 2D 피쳐 기반 학습

- $\text{Income} = f^*(\text{Years of Education}, \text{Seniority}) + \epsilon$
 - 파란색 Surface(=미지의 참 함수 f)는 관측 불가능
 - 빨간색 점들(=데이터)만 관측 가능함
 - 학습 전 : 어떤 가설공간 F를 사용할까?
 - 학습 후 : 데이터를 활용하여 어떤 모델 f를 선택해야 할까?



4-2. ML 예시: 2D 피쳐 기반 학습

- $\text{Income} = f^*(\text{Years of Education}, \text{Seniority}) + \varepsilon$



4-3. 일반적 용어 정리 및 모델 가정

- $\text{Income} = f^*(\text{Years of Education}, \text{Seniority}) + \varepsilon \rightarrow Y = f^*(X) + \varepsilon$
 - Income : 우리가 예측하려는 라벨(반응/목표) 변수 $\rightarrow Y$ 로 표기
 - Year of Education : 첫번째 피쳐(입력/예측) 변수 $\rightarrow X_1$ 로 표기
 - Seniority : 두번째 피쳐(입력/예측) 변수 $\rightarrow X_2$ 로 표기
 - 다른 i번째 피쳐가 있다면 역시 X_i 로 표기
- 일반적인 p차원 피쳐(총 p개의 피쳐) 벡터: $X = [X_1 X_2 \dots X_p] \in \mathbb{R}^p$
- 모델(함수형) : $Y = f^*(X) + \varepsilon$
 - ε : 측정오차를 나타내며, X와 독립 및 $E[\varepsilon] = 0$ 로 가정함

4-4. 왜 $f(X)$ 를 학습하는가?

- 예측
 - 잘 학습된 f 가 있으면, 새로운 입력 $X=x$ 에서 반응/목표 Y 를 예측할 수 있음
- 중요 특성 파악
 - $X = (X_1, X_2, \dots, X_p)$ 의 어떤 특성이 Y 를 설명하는 데 중요하고, 어떤 것은 덜 중요(무관)한 지 알 수 있음

- 해석 가능성
 - f의 복잡도에 따라 각 구성요소 X_j 가 Y에 어떻게 영향을 미치는지(증가/감소 방향, 민감도 등) 이해할 수 있음

2. 지도학습은 무엇인가?

학습시작(Overview)

- 지도 학습 : “훈련 데이터가 아니라, 처음 보는 데이터에서의 예측 성능 향상”
 - 지도 학습은 입력+정답(레이블)을 가지고 예측 규칙을 배우는 방법


학습 목표

- 회귀(연속값)와 분류(범주값)의 문제 정의와 출력 차이 이해
- 문제 유형에 맞는 오류/평가 지표를 바르게 선택, 해석
- 학습의 목적: 테스트 성능 최대화에 대한 이해
- 오버피팅(overfitting)의 뜻 이해

1. 지도학습의 개념

1-1. 지도학습(supervised learning)이란?

- 데이터
 - 입력(특성)과 정답(라벨)이 쌍으로 있는 데이터
- 목표
 - 새 입력이 들어오면 정답을 잘 맞추는 규칙을 학습
- 지도학습의 종류
 - 회귀 : 예측 값이 숫자(가격, 점수, 온도)
 - 분류 : 예측 값이 범주(스팸/정상, 질병 유/무)




1-2. 지도학습 용어

- 특성(Feature, x): 예측에 쓰는 설명 변수
- 라벨(Label, y): 맞춰야 하는 정답
- 예측값(y_h): 모델이 내놓은 결과(숫자 또는 범주)
- 오류(Error) : 예측값(y_h)과 라벨(y)의 차이

2. 회귀(Regression)

2-1. 회귀(Regression) 문제

- 질문 : 입력으로부터 숫자를 얼마나 정확히 예측할까?
- 라벨 및 예측 모델의 출력 : 연속적인 수치



2-2. 회귀 오류:평균제곱오차(MSE)

- 평균제곱오차(Mean Squared Error): 각 데이터에서 정답(y_i)과 예측(y_{hi})의 평균 제곱 차이값.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 해석 : 큰 오차를 더 크게 벌주므로, 전체 오차 수준을 한눈에 본다.
- 참고 : 데이터와 같은 단위를 쓰고 싶으면 RMSE(MSE의 제곱근)도 사용

2-3. 회귀 설명력: R^2 (결정계수)

- 결정계수 : 라벨의 분산 중에서 특성으로 설명되는 비율
 - 평균만 쓰는 단순한 예측보다 얼마나 더 잘 맞추는지를 0~1 사이로 나타낸 값.


$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad \bar{y} = y_i \text{들의 평균값}$$

- 해석 : 1에 가까울수록 설명력이 높고, 낮을 수록 설명력이 낮다.
- 질문 : R^2이 음수가 나올 수 있을까?
- 답변 : 모델의 예측 오차(분자)가 데이터의 단순 평균으로 예측했을 때의 오차(분모)보다 크면 음수가 나온다. 평균 값으로 예측하는 것보다도 못하다는 의미이다.

3. 분류(Classfication)

3-1. 분류(Classfication) 문제

- 질문 : 입력으로부터 범주를 얼마나 정확히 가려낼까?
- 라벨 : 범주 라벨(이진/다중)



3-2. 분류 정확도(Accuracy)

- 정확도 = 전체 중 맞춘 비율

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y_i = \hat{y}_i)$$

$\mathbb{I}$: 지시(indicator) 함수
 $\mathbb{I}(A) = 1$ if A true

- 정확도만 보면 발생하는 문제
 - 불균형 데이터(양성 1%, 음성 99%)에서는 전부 음성이라 해도 정확도가 99%로 보일 수 있음.
- 결론 : 정확도만 보지 말고 다른 지표도 함께 봐야 안전

3-3. 혼동행렬(Confusion Matrix)

- 혼동행렬: 예측과 실제 값 사이의 관계를 행렬 형태로 표현

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

- TP : 실제 양성, 예측도 양성
- TN : 실제 음성, 예측도 음성
- FP : 실제 음성인데, 양성이라 함(오탐)
- FN : 실제 양성인데, 음성이라 함(누락)

3-4. 정밀도, 재현율, F1-score

- 정밀도(Precision): 양성이라 판정한 것 중 진짜 양성의 비율
- 재현율(Recall or Sensitivity) : 진짜 양성 가운데 잡아낸 예측 양성 비율
- F1-score: 정밀도와 재현율의 조화평균
 - $F1 = (2 * \text{정밀도} * \text{재현율}) / (\text{정밀도} + \text{재현율})$

4. 학습의 목적


4-1. 학습의 목적은 테스트 예측(일반화)

- 학습 모델의 성능 평가는 모델이 처음 보는 데이터로 평가함.
- 일반화(generalization) 오차의 최소화 지향
- 훈련 데이터에서 성능이 아무리 좋아도, 새 데이터에서 성능이 떨어지면 실전엔 쓸 수 없음.

- 다음 차시(검증/교차검증)에서 일반화 성능을 추정하는 방법을 배울 예정

4-2. 오버피팅(overfitting)이란?

- 과적합 : 훈련 데이터의 우연한 패턴/잡음까지 외워버려서(초록색함수) 훈련에서는 잘 맞지만 테스트에서는 성능이 나빠지는 현상
- 흔한 징후
 - 훈련 오류 급격히 낮음, 테스트 오류 높음/요동




4-3. 오버피팅에 대한 오해

- 오버피팅: 훈련과 같은 분포에서 볼 때, 모델이 훈련 데이터의 우연, 잡음까지 외워 훈련 오차는 낮지만 검증/테스트 오차가 높아지는 현상
- 분포변화(데이터 쉬프트): 훈련 분포와 실제/테스트 분포가 달라져(환경, 계절, 센서 변경등) 성능이 떨어지는 현상. 모델이 과복잡하지 않아도 발생 가능

4-4. 오버피팅 vs 언더피팅 (균형잡기)

- 오버피팅: 모델이 너무 복잡 → 잡음까지 학습(테스트 성능 나쁨)
- 언더피팅: 모델이 단순하거나 학습이 완료되지 않음 → 중요한 패턴을 놓침(오류 큼)



- 해결 실마리 : 더많은 데이터, 모델 정규화

3. 교차검증(Cross-Validation)

학습 목표

- 훈련 오차 vs 테스트오차의 차이를 말하고, 왜 테스트 예측(일반화)이 목표인지 설명한다.

- 검증셋(hold-out), K-겹 교차검증(K-fold Cross-Validation)의 개념과 차이를 구분한다.
- 데이터 누수(leakage)가 어떤 문제가 생기는 지 설명한다.


1. 테스트 성능 평가

1-1. 훈련 성능 != 테스트 성능

- 훈련 오차 vs 테스트 오차
 - 훈련 오차 : 모델을 학습시킨 같은 데이터에 다시 적용해 계산한 오류
 - 테스트오차 : 학습에 쓰지 않은 새 관측치에 대해 모델을 적용했을 때의 평균 예측 오류
- 보통 훈련오차는 테스트오차와 다르며, 특히 훈련오차는 테스트오차를 심하게 과소평가하는 경우가 많다.
- 직관적인 예 : 암기 vs 응용 시험

1-2. 언더피팅, 오버피팅 곡선

- 모델이 단순하면 성능을 놓치고(언더), 너무 복잡하면 데이터 자체를 외움(오버)
- 훈련 오류는 계속 떨어지는 데, 테스트 오류는 U자형
- 목적 : U자형의 바닥(최적 복잡도) 찾기



1-3. 예측 오류를 추정하는 방법

- 이상적 케이스: 충분히 큰 별도 테스트 셋 → 현실에선 구하기 어려움
- 대안 : 훈련 관측치 일부를 보류(hold-out)하고 그에 대해 예측해 테스트오차를 추정하는 방법에 집중한다.

1-4. 재표본화(resampling)를 통한 테스트 오차 추정

- 데이터를 나눠 여러 번 “훈련 → 평가” 를 반복해 테스트 오류를 가늠
- 방법: 검증셋(hold-out), K겹 교차검증(K-fold Cross-Validation)
- 장점: 별도의 테스트 데이터 없이 데이터를 더 효율적으로 사용하여 일반화 오차 추정

2. 검증셋(validation set) 접근


2-1. 검증셋(hold-out) 방법

- 가용 샘플들을 무작위로 훈련셋과 검증셋(hold-out)으로 분할.

- 훈련셋으로 모델적합, 검증셋으로 예측 후 검증 오차를 계산.
- 검증 오차는 보통 정량 반응은 MSE, 범주 반응은 오분류율(또는 F1-score)을 측정한다.


2-2. 검증(Validation) 절차

- 데이터 순서 무작위 셔플링 후 두 부분으로 분할: 왼쪽=훈련셋, 오른쪽=검증셋.
- 학습은 훈련셋에서, 성능평가는 검증셋에서 수행.



2-3. 예: 자동차 데이터

- 목표: 선형(1차)항 vs 고차항(다항식) 비교(회귀)
- 392개 데이터를 무작위로 196개 데이터 훈련셋/196개 데이터 검증으로 분할.
- 좌측 패널 : 단 한번 분할 시의 MSE 곡선
- 우측 패널 : 여러 번 다른 분할의 MSE 곡선.



- 질문 : 이 예시에서 보이는 검증셋 방법의 단점이 무엇일까?
- 데이터 분할의 임의성 문제, 데이터를 한번만 훈련/검증으로 나누면, 어떻게 나눴는지에 따라 MSE 값이 크게 달라질 수 있다. (불안정성 문제)
- 이 단점을 보완하기 위해 데이터를 여러 번 나누어 평균적인 성능을 확인한다. (K-fold cross validation)

2-4. 검증셋 접근의 한계

- 어떤 표본이 훈련/검증에 들어가느냐에 따라 검증 기반 테스트오차 추정치가 매우 가변적이다.
- 검증 접근에서는 훈련셋(=전체의 일부)만으로 모델을 적합하므로, 전체 데이터로 학습했을 때보다 성능이 낮게(테스트 오차를 크게) 추정 될 수 있다.
- 질문: 왜 전체 데이터로 학습한 모델의 테스트 오차를 과대추정하는 경향이 있을까?
- 답변: 데이터 활용량의 차이, 전체 데이터를 사용해 학습한 모델의 오차를 원하지만, 실제로는 전체 데이터 셋의 일부(학습데이터)만으로 모델을 학습 하여 모델이 덜 학습되게 된다. 데이터가 적을 수록 모델의 파라미터 추정이 불안정해지고, 결과적으로 검증셋에서의 테스트


오차 추정치가 커지게 된다.

3. K-겹 교차검증(K-fold Cross-Validation)

3-1. K-겹 교차검증(K-fold Cross-V)

- 테스트오차 추정의 표준적 접근
- 추정치는 모델 선택과 최종 모델의 테스트오차 규모 파악에 활용된다.
- 데이터 전체를 크기 동일한 K개 폴드로 무작위 분할
- 폴드 k 가 {1,2,...,K} 에 속하는 지를 검증
- k=1, ..., K 에 대해 반복 후, 평균 오차로 테스트오차를 추정.

3-2. K-겹 교차검증 단계



- 데이터를 먼저 셔플링한 뒤, 총 n 개의 데이터를 겹치지 않게 K개 그룹으로 분할한다.
- 각 그룹이 번갈아 검증셋(베이지), 나머지는 훈련셋(파란색)이 된다.
- K개의 MSE를 평균해 테스트오차를 추정

3-3. K-겹 교차검증 오류 계산


- 폴드 집합 C1, ... , CK , 각 폴드 크기 nk.

$$CV(K) = \sum_{i=1}^n \frac{n_k}{n} MSE_k$$

$$MSE_k = \frac{1}{n_k} \sum_{i \in C_k} (y_i - \hat{y}_i)^2 \text{ (k-폴드를 검증셋으로 두고 나머지로 적합한 예측 } \hat{y}_i \text{.)}$$


- K=n 이면 Leave-One-Out 교차검증(LOOCV)
- 질문 : Leave-One-Out 교차검증에서 검증셋 크기는?
- 답변 : 검증셋 크기는 항상 1개 데이터 포인트

3-4. Leave-One-Out 교차검증




- 훈련셋(파랑) : 관측치 하나만 제외한 나머지 전부
- 검증셋(베이지): 제외한 그 1개 관측치
→ 이 과정을 n번 반복해 나온 n개의 MSE 평균으로 테스트 오차를 추정.

3-5. Leave-One-Out 교차검증 vs 10겹 교차검증



- 자동차 데이터에서 LOOCV와 10-겹 CV 결과 비교(다항 차수에 따른 MSE 곡선).
→ 두 방법의 경향과 최적 차수가 비슷함

3-6 시뮬레이션: 참/추정 테스트 MSE



- 파랑 : 참(test) MSE, 검은 점선 : LOOCV추정, 주황: 10-겹 CV 추정
- 10-겹 cv 추정 : 테스트 성능 추정의 좋은 대안

4. 교차검증 시 주의점

4-1. 옳은 CV vs 잘못된 CV

이진 분류 예(간단분류기) :

- 1. 5000개 특성과 50개 샘플에서 라벨과 상관이 큰 상위 100개 특성을 선택
- 2. 선택된 100개만으로 로지스틱 회귀 등 분류 모델을 학습.

테스트 성능을 어떻게 추정할까?

- 잘못된 방법 : 2단계(분류기 학습)에만 CV 적용(1단계 무시).
- 옳은 방법: 각 폴드 안에서 1단계(특성선정)와 2단계(학습)를 함께 수행, 그 결과로 평가
- 왜? 1단계에서 이미 라벨을 사용했으므로, 이것도 훈련 과정의 일부로 간주되어야 정보의 누수(leakage)가 없다.

4. 비지도 학습은 무엇인가?


1. 비지도 학습

1-1. 비지도학습이란?

- 정의 : 레이블(정답) 없이 데이터의 구조, 패턴, 집단(잠재 서브그룹)을 찾아내는 학습.
- 대표 과제 : 군집화(clustreing), 차원축소(PCA 등), 밀도추정/이상치 탐지
- 핵심 질문
 - 무엇을 비슷함/다름으로 볼 것인가(거리, 유사도 선택)
 - 전처리(스케일 표준화 등)을 어떻게 할 것인가
- 출력: "정답예측 " 이 아니라 구조/요약/표현(embedding).

1-2. 비지도vs지도, 그리고 클러스터링

- 지도(supervised)학습: 입력+라벨로 예측 모델 학습
- 비지도(unsupervised)학습: 입력만으로 구조 학습
- 클러스터링: 서로 비슷한 데이터끼리 묶어 동질 그룹 만들기




2. 클러스터링

2-1. 클러스터링(Clustering)이란?

- 클러스터링: 데이터 안에서 하위 집단(클러스터)을 찾는 기법들의 총칭.

- 목표: 집단 내부는 서로 유사, 집단 간은 상이하도록 데이터를 분할.
- 유사/상이 정도는 도메인 맥락에 따라 정의가 달라질 수 있음
- 문제: 데이터 특성에 의존



2-3. 두 가지 대표 클러스터링 기법


- K-평균(K-means) : K(클러스터 수)를 미리 정해 분할
- 계층적 군집(Hierarchical): K를 사전에 고정하지 않음.



3. K-means 클러스터링

3-1. K-means 클러스터링

- 패널: K=2, 3, 4 에서 K-means 결과(점 색상=할당된 클러스터)
- 클러스터 번호엔 순서 의미 없음(색상은 임의)



3-2. K-means의 표기(군집 집합)

- 관측치 인덱스 집합을 $C_1, \dots, C_k$ 라 하면:
 - $C_1 \cup \dots \cup C_k = \{1, \dots, n\}$ (각 관측치는 적어도 하나의 군집에 속함)
 - 모든 다른 클러스터 $k \neq k'$ 에 대해 $C_k \cap C_{k'} = \emptyset$ (겹치지 않음)
- i 번째가 k 번째 군집이면, i 가 C_k 에 속함. (비중첩 분할)

3-3. K-means의 핵심 아이디어


- 좋은 군집화 = 클러스터 내부 변동(Within-Cluster Variation)이 작은 분할
- 목표 : 클러스터 내부 변동의 합이 최소가 되도록 분할을 찾는다.
- "모든 클러스터의 내부 흠어짐 총합이 가장 작은 분할 "

3-4. K-means 알고리즘

- 초기화 : 관측치들에 무작위로 $1, \dots, K$ 클러스터를 임시 부여.
- 반복(할당이 더 이상 바뀌지 않을 때까지):
 - 2a. 각 클러스터의 중심(centroid) 계산(특성 평균 벡터)
 - 2b. 각 관측치를 가장 가까운 중심의 클러스터에 재할당(거리 예=유클리드)
- 위 반복은 매 단계 목표함수 값을 감소시킴(군집 내 평균 제곱거리의 성질 때문)
- 단, 전역 최솟값 보장은 아님 → 초기값에 따라 지역 최솟값으로 수렴 가능


3-5. K-means 알고리즘 단계별 진행

- Step1 : 무작위 클러스터 초기화
 - Iteration 1, Step2a: 중심 계산
 - Iteration 2, Step2b: 클러스터 재배정
 - Iteration 3, Step2a: 중심 (재)계산



3-6. 다른 초기 값의 영향

- 서로 다른 초기 레이블에서 최종 분할과 목표값(패널 상단 숫자)이 달라짐.
- 초기화의 중요성 : 여러 번 시도 권장




4. 계층적 군집(Hierarchical Clustering)

4-1. 계층적 군집(Hierarchical Clustering)

- K-means는 클러스터 수 K를 미리 지정해야 하는 단점.
- 계층적 군집은 K를 고정하지 않고 전체 구조를 덴드로그램으로 제공.
- 여기서는 하향식이 아닌, 상향식(agglomerative)을 다룸: 앞→몸통으로 병합


4-2. 계층적 군집 결과 예시

- 덴드로그램에서 수평선 높이(거리)를 기준으로 가위질하여 K개 군집을 얻는다.




4-3. 계층적 군집 알고리즘(상향식)

1. n 개 관측에 대해 쌍별 비유사도를 계산, 각 관측치를 하나의 클러스터로 시작.
2. $i=n, n-1, \dots, 2$ 에 대해 반복:
 - 2a. i 개 클러스터 간 쌍별 비유사도를 모두 계산해 가장 유사한 두 클러스터를 병합
 - 2b. 병합 후 남은 $i-1$ 개 클러스터 사이의 새 비유사도를 다시 계산.




4-4. 계층적 군집 병합 진행 예

- 데이터들이 점차 큰 클러스터로 합쳐지는 과정.
- 매 단계에서 클러스터들끼리의 병합이 이루어짐.
- 1개의 단일 클러스터가 될 때까지 진행




4-5. 링크(link) 유형

- Single(최소 거리) 링크 : 두개 클러스터 내 데이터 쌍별 거리 중 최소값을 군집 간 거리로
- Complete(최대 거리) 링크 : 두개 클러스터 내 데이터 쌍별 거리 중 최대값을 군집 간 거리로
- Average(평균 거리) 링크: 두개 클러스터 내 데이터 쌍별 거리의 평균을 군집 간 거리로



4-6. 링크에 따라 결과가 달라진다.

- 같은 데이터라도 링크 선택에 따라 클러스터링 결과(덴드로그램)가 달라질 수 있음
- 하나의 링크만 시도하는 것이 아니라 다른 종류의 링크도 사용 권장



5. 클러스터링 시 주의점

5-1. 클러스터링 체크리스트

- 스케링일이 매우 중요
 - 표준화(평균 0, 표준편차 1로 입력 변수 변환)가 필요한가?
 - Yes, 변수 단위 차이 영향 큼.
- 몇 개의 클러스터가 적합한지? → 정답이 없음
- 단일 시도가 아닌 여러 번 시도 권장됨