

AI 시험 대비 모의고사 180 제

6 개 단원 x 30 문항 | 4 지선다형

출제 범위

- 1-1. AI & 기계학습 기초
- 1-2. AI & 기계학습 방법
- 2-1. 자연어 처리 기본
- 2-2. 텍스트 파운데이션 모델
- 3-1. 딥러닝 & 영상모델
- 3-2. 이미지 파운데이션 모델

제공된 PDF 교안과 노선의 단원 구성에 근거해 제작

응시 안내

1. 총 180 문항이며, 각 문항은 4 개의 보기 중 가장 적절한 답 1 개를 선택합니다.
2. 문항은 제공된 교안의 정의, 비교, 핵심 원리, 간단한 계산/상황 판단 중심으로 구성했습니다.
3. 정답과 간단 해설은 문제지 뒤쪽의 "정답 및 해설"에 수록했습니다.
4. 먼저 답안 기록표에 답을 적은 뒤, 모든 문제를 푼 후 해설을 확인하는 방식으로 사용하세요.

답안 기록표

1-1. AI & 기계학습 기초

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

1-2. AI & 기계학습 방법

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

2-1. 자연어 처리 기본

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

2-2. 텍스트 파운데이션 모델

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

3-1. 딥러닝 & 영상모델

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

3-2. 이미지 파운데이션 모델

1 —	2 —	3 —	4 —	5 —	6 —	7 —	8 —	9 —	10 —
11 —	12 —	13 —	14 —	15 —	16 —	17 —	18 —	19 —	20 —
21 —	22 —	23 —	24 —	25 —	26 —	27 —	28 —	29 —	30 —

PART 1 1-1. AI & 기계학습 기초

1. AI와 머신러닝(ML)의 관계에 대한 설명으로 가장 적절한 것은?

- 1) AI와 ML은 완전히 같은 개념이다.
- 2) ML은 AI 범주 안에서 데이터로부터 학습하는 접근 방법론이다.
- 3) AI는 반드시 ML을 사용해야만 구현할 수 있다.
- 4) ML은 데이터를 사용하지 않는 규칙 기반 시스템이다.

2. 머신러닝에서 Feature(특성)의 역할로 가장 적절한 것은?

- 1) 모델이 예측하려는 정답
- 2) 모델이 예측에 사용하는 정보
- 3) 학습이 끝난 뒤 계산되는 오류
- 4) 모델 후보들의 집합

3. 머신러닝에서 Label(라벨)에 대한 설명으로 옳은 것은?

- 1) 모델이 예측하려는 정답
- 2) 모델의 학습률
- 3) 입력 변수의 개수
- 4) 훈련 데이터의 잡음

4. 가설공간(Hypothesis Space)의 의미로 가장 적절한 것은?

- 1) 관측된 모든 라벨의 집합
- 2) 관계를 표현할 수 있는 모든 후보 함수의 모음
- 3) 학습 후 선택된 하나의 함수
- 4) 오차가 없는 데이터 집합

5. 교안의 정의에 따르면 학습(learning)이란 무엇인가?

- 1) 데이터를 모두 암기하는 과정
- 2) 가설공간의 후보 중 주어진 데이터와 성능척도에 따라 최적의 모델을 선택하는 과정
- 3) 라벨 없이 데이터를 군집화하는 과정만을 의미
- 4) 입력 차원을 늘리는 과정

6. 1D 피쳐 기반 학습의 의미는?

- 1) 라벨이 1 개라는 뜻
- 2) 피쳐가 하나인 가장 단순한 학습 형태
- 3) 모델이 하나뿐이라는 뜻
- 4) 데이터가 한 개라는 뜻

7. 모델 가정 $Y = f^*(X) + \varepsilon$ 에서 교안이 ε 에 대해 두는 가정으로 옳은 것은?

- 1) ε 는 X 와 완전히 동일하다.
- 2) ε 의 평균은 항상 1이다.
- 3) ε 는 X 와 독립이고 $E[\varepsilon]=0$ 으로 가정한다.
- 4) ε 는 반드시 음수이다.

8. 지도학습의 회귀(Regression) 문제에 해당하는 예시는?

- 1) 메일을 스팸/정상으로 구분
- 2) 질병 유/무 판정
- 3) 주택 가격 예측
- 4) 사진을 고양이/개로 구분

9. 평균제곱오차(MSE)의 특징으로 옳은 것은?

- 1) 오차의 절댓값 중 최댓값만 사용한다.
- 2) 오차를 제곱하므로 큰 오차를 더 크게 벌준다.
- 3) 분류 문제에서만 사용할 수 있다.
- 4) 값이 클수록 좋은 모델이다.

10. MSE 대신 RMSE를 사용하는 이유로 교안에서 제시한 것은?

- 1) 정확도를 0~1로 만들기 위해
- 2) 데이터와 같은 단위로 오류를 보고 싶을 때
- 3) 분류 라벨을 만들기 위해
- 4) 모델 파라미터 수를 줄이기 위해

11. R^2 (결정계수)에 대한 설명으로 가장 적절한 것은?

- 1) 항상 0보다 크다.
- 2) 1에 가까울수록 설명력이 높다.
- 3) 값이 작을수록 모델이 우수하다.
- 4) 분류 정확도와 완전히 같은 지표이다.

12. R^2 가 음수가 될 수 있는 상황으로 옳은 것은?

- 1) 모델 예측오차가 평균값으로 예측한 오차보다 더 큰 경우
- 2) 훈련 데이터가 100 개 미만인 경우
- 3) 피처가 하나뿐인 경우
- 4) MSE가 0인 경우

13. 불균형 데이터에서 Accuracy만 사용할 때의 문제점으로 가장 적절한 것은?

- 1) 정확도가 항상 0이 된다.
- 2) 소수 클래스는 거의 맞이지 못해도 높은 정확도가 나올 수 있다.
- 3) 혼동행렬을 만들 수 없다.
- 4) 회귀 문제로 자동 변환된다.

14. 실제는 음성인데 모델이 양성이라고 예측한 경우는?

- 1) TP
- 2) TN
- 3) FP
- 4) FN

15. 정밀도(Precision)의 의미는?

- 1) 실제 양성 중 맞힌 비율
- 2) 양성으로 예측한 것 중 실제 양성 비율
- 3) 전체 중 맞힌 비율
- 4) 정밀도와 재현율의 산술평균

16. 재현율(Recall)의 의미는?

- 1) 진짜 양성 가운데 모델이 양성으로 잡아낸 비율
- 2) 예측 음성 중 실제 음성 비율
- 3) 전체 샘플 중 오답 비율
- 4) 회귀계수의 크기

17. F1-score에 대한 설명으로 옳은 것은?

- 1) 정밀도와 재현율의 조화평균
- 2) 정확도와 MSE의 평균
- 3) TP와 TN의 차이
- 4) R^2 의 제곱근

18. 지도학습에서 궁극적으로 지향하는 성능은?

- 1) 훈련 데이터에서의 암기 성능
- 2) 처음 보는 데이터에서의 일반화 성능
- 3) 파라미터 수 최대화
- 4) 훈련 오차를 항상 0으로 만드는 것

19. 오버피팅(overfitting)에 대한 설명으로 옳은 것은?

- 1) 모델이 너무 단순해 중요한 패턴을 놓치는 현상
- 2) 훈련 데이터의 잡음까지 외워 훈련 성능은 좋지만 테스트 성능이 나빠지는 현상
- 3) 훈련과 테스트 분포가 달라지는 현상만을 의미
- 4) 데이터가 부족하면 반드시 발생하지 않는 현상

20. 데이터 시프트와 오버피팅을 구분한 설명으로 옳은 것은?

- 1) 둘은 완전히 같은 현상이다.
- 2) 데이터 시프트는 훈련 분포와 실제/테스트 분포가 달라져 성능이 떨어지는 현상이다.
- 3) 오버피팅은 모델이 단순할수록 생긴다.
- 4) 데이터 시프트는 훈련 오차가 0일 때만 생긴다.

21. 언더피팅(underfitting)의 특징으로 가장 적절한 것은?

- 1) 모델이 지나치게 복잡해 잡음까지 외움
- 2) 모델이 단순하거나 학습이 충분하지 않아 중요한 패턴을 놓침
- 3) 테스트 성능은 항상 완벽함
- 4) 라벨이 없는 데이터에서만 발생

22. 훈련 오차와 테스트 오차의 관계에 대한 설명으로 옳은 것은?

- 1) 항상 정확히 같다.
- 2) 훈련 오차는 테스트 오차를 과소평가하는 경우가 많다.
- 3) 테스트 오차가 존재하면 학습은 불가능하다.
- 4) 훈련 오차는 새 데이터에서 계산한다.

23. 검증셋(hold-out) 접근의 기본 절차로 옳은 것은?

- 1) 전체 데이터를 모두 검증에만 사용
- 2) 데이터를 훈련셋과 검증셋으로 나누고 훈련셋으로 적합한 뒤 검증셋에서 평가
- 3) 검증셋으로 학습하고 훈련셋으로 평가
- 4) 라벨을 제거한 뒤 군집화

24. 단 한 번의 hold-out 분할이 가진 주요 한계는?

- 1) 항상 계산량이 너무 크다.
- 2) 어떻게 나누었는지에 따라 검증 오차가 크게 달라질 수 있다.
- 3) 훈련셋이 전체 데이터보다 항상 크다.
- 4) 분류에는 사용할 수 없다.

25. K-fold 교차검증에 대한 설명으로 옳은 것은?

- 1) 항상 $K=1$ 이다.
- 2) 데이터를 K 개 폴드로 나누고 각 폴드가 한 번씩 검증셋이 되도록 반복한 뒤 평균 오차를 구한다.
- 3) 매 반복마다 모든 데이터를 검증셋으로 쓴다.
- 4) 라벨을 사용하면 안 된다.

26. LOOCV(Leave-One-Out Cross-Validation)의 검증셋 크기는?

- 1) 항상 전체 데이터의 절반
- 2) 항상 10 개
- 3) 항상 1 개 관측치
- 4) K 에 따라 무작위

27. 특성 선택 후 분류 모델을 학습할 때 올바른 교차검증 방식은?

- 1) 특성 선택은 전체 데이터에서 한 번 하고 분류기에만 CV 적용
- 2) 각 폴드 내부에서 특성 선택과 모델 학습을 모두 수행
- 3) 라벨을 먼저 섞은 뒤 수행
- 4) 검증 폴드의 라벨을 특성 선택에 사용

28. 비지도학습에 대한 설명으로 옳은 것은?

- 1) 항상 입력과 정답 라벨이 함께 필요하다.
- 2) 라벨 없이 데이터의 구조나 패턴을 찾는다.
- 3) 회귀만 수행한다.
- 4) 모델의 출력은 반드시 클래스 번호이다.

29. K-means 의 핵심 목표로 가장 적절한 것은?

- 1) 클러스터 간 거리의 합을 최소화
- 2) 클러스터 내부 변동의 총합을 작게 만드는 분할을 찾는 것
- 3) K 를 자동으로 무한히 증가시키는 것
- 4) 라벨 정확도를 최대화하는 것

30. K-means 와 계층적 군집 및 전처리에 대한 설명 중 옳은 것은?

- 1) K-means 는 초기값에 상관없이 항상 같은 전역 최적해를 보장한다.
- 2) 계층적 군집은 반드시 K 를 사전에 고정해야 한다.
- 3) 변수 단위 차이가 크면 표준화가 중요할 수 있다.
- 4) Single/Complete/Average 링크는 모두 항상 같은 덴드로그램을 만든다.

PART 2 1-2. AI & 기계학습 방법

1. 선형회귀의 기본 가정으로 가장 적절한 것은?

- 1) Y가 입력 변수들에 선형적으로 의존한다고 가정한다.
- 2) Y는 반드시 범주형이다.
- 3) 오차항이 존재하지 않는다고 가정한다.
- 4) 입력 변수는 반드시 하나여야 한다.

2. 단순 선형회귀 모형 $Y = \beta_0 + \beta_1 X + \varepsilon$ 에서 β_1 은 무엇을 의미하는가?

- 1) 절편
- 2) 기울기
- 3) 잔차
- 4) 학습률

3. i 번째 관측치의 잔차(residual) 정의로 옳은 것은?

- 1) $e_i = \hat{y}_i - y_i$
- 2) $e_i = y_i - \hat{y}_i$
- 3) $e_i = y_i + \hat{y}_i$
- 4) $e_i = y_i / \hat{y}_i$

4. 최소제곱법(least squares)의 목적은?

- 1) RSS를 최대화하는 계수를 찾는 것
- 2) RSS를 최소화하는 계수를 찾는 것
- 3) R^2 를 항상 0으로 만드는 것
- 4) 모든 잔차를 양수로 만드는 것

5. RSS에 대한 설명으로 옳은 것은?

- 1) 잔차의 합
- 2) 잔차 절댓값의 최댓값
- 3) 잔차 제곱의 합
- 4) 회귀계수 제곱의 합

6. 단순 선형회귀 결과에서 회귀계수의 p-value가 매우 작다는 것은 교안의 예시에서 무엇을 시사하는가?

- 1) 관계가 없다는 귀무가설을 기각하기 어렵다.
- 2) 설명변수와 반응변수 사이에 유의한 관계가 있다고 판단할 근거가 된다.
- 3) R^2 가 반드시 1이다.
- 4) 잔차가 모두 0이다.

7. 광고 데이터 예시에서 $R^2=0.612$ 의 해석으로 적절한 것은?

- 1) 매출 변동의 약 61.2%를 TV 광고비로 설명할 수 있다.
- 2) 예측이 61.2% 틀렸다.
- 3) TV 광고비가 61.2만큼 증가한다.
- 4) 모델이 분류 정확도 61.2%라는 뜻이다.

8. 다중선형회귀 모형에 대한 설명으로 옳은 것은?

- 1) 설명변수를 하나만 사용한다.
- 2) 여러 설명변수 $X_1, \dots, X_p$ 를 사용해 Y를 설명한다.
- 3) 범주형 출력만 예측한다.
- 4) 잔차를 사용할 수 없다.

9. 다중선형회귀에서 β_j 의 해석으로 가장 적절한 것은?

- 1) 다른 변수를 고정한 채 X_j 가 1단위 증가할 때 Y의 평균 변화량
- 2) 모든 변수의 합
- 3) X_j 의 분산
- 4) Y의 최댓값

10. 이진 분류에서 선형회귀 예측값을 확률로 직접 해석할 때 생길 수 있는 문제는?

- 1) 항상 0.5만 나온다.
- 2) 예측값이 0보다 작거나 1보다 클 수 있다.
- 3) 입력 변수를 사용할 수 없다.
- 4) 학습이 불가능하다.

11. 로지스틱 회귀가 분류에 적합한 이유 중 하나는?

- 1) 출력이 항상 정수만 된다.
- 2) 출력을 0~1 사이 값으로 만들 수 있다.
- 3) 잔차를 사용하지 않는다.
- 4) 설명변수가 없어도 된다.

12. 로지스틱 회귀의 모수 추정에 교안에서 제시한 방법은?

- 1) K-means
- 2) MLE(Maximum Likelihood Estimation)
- 3) PCA
- 4) LOOCV

13. Shallow Network 의 정의로 옳은 것은?

- 1) 은닉층이 없는 네트워크
- 2) 은닉층이 1 개인 신경망
- 3) 출력층이 1 개인 모든 신경망
- 4) 은닉층이 10 개 이상인 신경망

14. ReLU 활성화 함수의 동작으로 옳은 것은?

- 1) 음수는 0, 양수는 그대로 출력
- 2) 모든 입력을 1 로 출력
- 3) 양수를 0 으로 만든다.
- 4) 입력의 제곱을 출력

15. 신경망에서 '학습한다'는 표현과 가장 직접적으로 연결되는 것은?

- 1) 파라미터를 구하고 조정하는 것
- 2) 입력 데이터를 삭제하는 것
- 3) 은닉층을 항상 늘리는 것
- 4) 출력을 무작위로 만드는 것

16. Piecewise linear 함수의 의미는?

- 1) 전체 구간이 하나의 직선인 함수
- 2) 전체는 비선형이지만 구간별로 선형인 함수
- 3) 항상 0 인 함수
- 4) 확률만 출력하는 함수

17. Hidden Unit 에 대한 설명으로 가장 적절한 것은?

- 1) 입력 데이터 자체
- 2) 신경망 중간 단계의 연산 단위
- 3) 정답 라벨
- 4) 테스트 데이터

18. 1 차원 입력에서 Hidden Unit 의 수를 늘렸을 때 교안이 설명한 효과는?

- 1) 그래프의 꺾임을 더 많이 만들 수 있다.
- 2) 항상 직선만 표현한다.
- 3) 출력이 사라진다.
- 4) 학습률이 자동으로 0 이 된다.

19. 보편근사정리(Universal Approximation Theorem)에 대한 교안의 설명으로 옳은 것은?

- 1) 은닉층이 1 개여도 Hidden Unit 이 충분하면 연속함수를 원하는 정밀도로 근사할 수 있다.
- 2) 은닉층이 1 개면 선형함수만 표현 가능하다.
- 3) 은닉층 수와 표현력은 무관하다.
- 4) 모든 데이터에 대해 정확히 0 의 오차를 보장한다.

20. 동일한 Hidden Unit 을 공유하는 다중 출력 Shallow Network 에 대한 설명으로 옳은 것은?

- 1) 출력마다 Hidden Unit 의 꺾이는 위치가 반드시 달라진다.
- 2) 출력이 여러 개여도 꺾이는 위치는 Hidden Unit 에 의해 정해진다.
- 3) 출력은 하나만 가능하다.
- 4) 입력 개수는 반드시 2 개이다.

21. Deep Network 의 정의로 옳은 것은?

- 1) 은닉층이 2 개 이상인 신경망
- 2) 가중치가 없는 신경망
- 3) 출력이 2 개인 신경망
- 4) 학습률이 큰 신경망

22. 두 개의 Shallow Network 를 합성했을 때의 효과로 교안에서 강조한 것은?

- 1) 표현력이 감소한다.
- 2) 표현력이 증가할 수 있다.
- 3) 모든 비선형성이 제거된다.
- 4) 파라미터가 없어지는 효과만 있다.

23. 경사하강법에서 파라미터를 업데이트할 때 사용하는 핵심 정보는?

- 1) 손실함수의 기울기
- 2) 분류 라벨의 개수만
- 3) 데이터 파일명
- 4) 클러스터 번호

24. 경사하강법에서 학습률(learning rate) α 의 역할은?

- 1) 업데이트 변화의 크기를 결정
- 2) 출력 클래스의 개수를 결정
- 3) 은닉층 개수를 결정
- 4) 데이터셋의 크기를 결정

25. Convex 문제의 특징으로 옳은 것은?

- 1) 지역 최소점이 매우 많다.
- 2) 전역 최소점이 유일해 최적화가 상대적으로 쉽다.
- 3) 신경망 학습에만 존재한다.
- 4) 기울기를 계산할 수 없다.

26. 신경망 최적화 문제에 대한 설명으로 옳은 것은?

- 1) 대부분 Convex 이다.
- 2) 대부분 Non-convex 여서 여러 지역 최소점이 존재할 수 있다.
- 3) 항상 닫힌형 해가 존재한다.
- 4) 손실함수를 사용하지 않는다.

27. SGD(Stochastic Gradient Descent)에 대한 설명으로 옳은 것은?

- 1) 항상 전체 데이터를 한 번에 사용
- 2) 한 번에 데이터 하나를 사용해 기울기를 계산
- 3) 라벨 없이 군집을 생성
- 4) 파라미터를 고정

28. Mini-batch SGD의 장점으로 교안이 제시한 것은?

- 1) SGD 보다 더 불안정하다.
- 2) 일부 샘플을 사용해 계산 효율과 안정성을 함께 얻을 수 있다.
- 3) 병렬 처리가 불가능하다.
- 4) 전체 배치보다 항상 느리다.

29. Epoch의 의미로 옳은 것은?

- 1) 데이터 전체를 한 번 학습하는 과정
- 2) 파라미터 하나를 제거하는 과정
- 3) 테스트 데이터만 한 번 보는 과정
- 4) 모델을 저장하는 횟수

30. 전체 데이터가 아니라 일부 데이터로 기울기를 계산할 때 발생하는 노이즈에 대한 교안의 설명으로 옳은 것은?

- 1) 항상 학습을 불가능하게 한다.
- 2) 계산을 빠르게 하고 지역 최소값에서 벗어나는 데 도움을 줄 수 있다.
- 3) 모든 기울기를 0으로 만든다.
- 4) Convex 문제를 Non-convex로 바꾸는 것이 유일한 목적이다.

PART 3 2-1. 자연어 처리 기본

1. 원-핫 인코딩(one-hot encoding)의 표현으로 옳은 것은?

- 1) 모든 원소가 1 인 벡터
- 2) 한 원소만 1 이고 나머지는 0 인 벡터
- 3) 항상 2 차원 벡터
- 4) 단어의 의미 유사도를 직접 담은 밀집 벡터

2. 원-핫 인코딩의 한계로 교안이 제시한 것이 아닌 것은?

- 1) 유사한 단어 사이 의미적 유사성을 표현하기 어렵다.
- 2) 어휘가 커지면 차원이 매우 커진다.
- 3) 고차원 희소벡터라 메모리 효율이 떨어질 수 있다.
- 4) 단어 간 의미적 관계를 밀집 벡터로 자연스럽게 표현한다.

3. 워드 임베딩(word embedding)의 핵심 특징은?

- 1) 단어를 고차원 희소 벡터로만 표현
- 2) 의미적 관계를 포착할 수 있는 밀집되고 연속적인 벡터 표현
- 3) 각 단어를 정수 하나로만 표현
- 4) 문장 순서를 제거하는 규칙

4. Word2Vec 의 Skip-gram 방식은 무엇을 예측하는가?

- 1) 주변 단어로 중심 단어를 예측
- 2) 중심 단어로 주변 단어를 예측
- 3) 문장 길이를 예측
- 4) 다음 문장의 라벨을 예측

5. Word2Vec 의 CBOW 방식은 무엇을 예측하는가?

- 1) 중심 단어로 주변 단어를 예측
- 2) 주변 단어들의 집합으로 중심 단어를 예측
- 3) 문장 전체를 이미지로 변환
- 4) 오디오 신호를 분류

6. 순차적 데이터의 특징으로 적절하지 않은 것은?

- 1) 순서가 중요하다.
- 2) 멀리 떨어진 과거 정보가 현재에 영향을 줄 수 있다.
- 3) 길이가 가변적일 수 있다.
- 4) 데이터 순서를 바꾸어도 의미가 항상 동일하다.

7. RNN 이 순차적 데이터 처리에 적합한 핵심 이유는?

- 1) 항상 고정 길이 입력만 받기 때문
- 2) 이전 시점 정보를 담은 hidden state 를 유지하기 때문
- 3) 모든 시점에서 다른 네트워크 구조를 사용하기 때문
- 4) 라벨 없이만 학습하기 때문

8. RNN 의 hidden state 업데이트 관계를 가장 잘 나타내는 것은?

- 1) $ht = fw(ht-1, xt)$
- 2) $ht = xt$ 만
- 3) $ht = label$ 만
- 4) $ht = 0$ 으로 고정

9. RNN 이 각 시점에서 동일한 가중치를 사용하는 효과로 교안이 설명한 것은?

- 1) 파라미터 효율성이 높다.
- 2) 시퀀스마다 별도의 모델이 필요하다.
- 3) 가변 길이 처리가 불가능하다.
- 4) 기울기 계산이 필요 없다.

10. RNN 의 기울기 소실(gradient vanishing)에 대한 설명으로 옳은 것은?

- 1) 역전파 중 작은 값이 반복 곱해져 기울기가 0 에 가까워지는 현상
- 2) 기울기가 무한히 커지는 현상
- 3) 출력 차원이 줄어드는 현상
- 4) 라벨이 사라지는 현상

11. RNN 의 기울기 폭발(gradient explosion)에 대한 설명으로 옳은 것은?

- 1) 작은 값이 반복 곱해져 0 이 됨
- 2) 큰 값이 반복 곱해져 기울기가 매우 커짐
- 3) 입력 토큰이 사라짐
- 4) 모델이 항상 수렴함

12. LSTM이 도입된 주요 배경은?

- 1) CNN의 공간 특징을 강화하기 위해
- 2) RNN의 장기 의존성과 기울기 소실 문제를 완화하기 위해
- 3) 이미지 해상도를 줄이기 위해
- 4) K-means의 초기값 문제를 해결하기 위해

13. LSTM의 Cell State 역할로 가장 적절한 것은?

- 1) 장기 정보를 저장하고 전달
- 2) 이미지의 픽셀을 압축
- 3) 분류 정확도를 계산
- 4) 출력 클래스를 임의 생성

14. LSTM의 Forget Gate가 하는 일은?

- 1) 이전 cell state에서 무엇을 버리고 유지할지 결정
- 2) 새 정보의 출력 확률을 정렬
- 3) 입력을 임베딩으로 바꾸기
- 4) 학습률을 자동으로 계산

15. LSTM의 Input Gate가 하는 일은?

- 1) 새 정보 중 얼마나 cell state에 쓸지 결정
- 2) 이전 정보만 삭제
- 3) 최종 클래스 번호를 결정
- 4) 모든 hidden state를 0으로 설정

16. LSTM의 Output Gate가 하는 일은?

- 1) cell state 중 얼마나 hidden state로 내보낼지 결정
- 2) 입력 토큰을 삭제
- 3) 과거 정보를 모두 보존
- 4) 어휘 사전 크기를 결정

17. 언어 모델(language model)의 역할로 가장 적절한 것은?

- 1) 단어 시퀀스에 확률을 부여하고 문맥에 따른 다음 단어 확률을 모델링
- 2) 이미지의 픽셀 색상을 군집화
- 3) 회귀계수만 추정
- 4) 텍스트를 항상 고정 길이로 변환

18. N-gram 언어모델은 다음 단어를 예측할 때 무엇을 고려하는가?

- 1) 앞선 N-1 개의 단어
- 2) 문장의 모든 미래 단어
- 3) 이미지 패치
- 4) 정답 라벨 하나만

19. Seq2Seq 구조의 기본 구성은?

- 1) Encoder + Decoder
- 2) CNN + K-means
- 3) PCA + Regression
- 4) Tokenizer + Accuracy

20. Seq2Seq에서 Encoder의 역할은?

- 1) 입력 문장 정보를 인코딩해 표현을 만든다.
- 2) 항상 정답 단어를 출력한다.
- 3) 모델의 학습률을 정한다.
- 4) 출력 문장을 평가만 한다.

21. Teacher Forcing의 의미로 옳은 것은?

- 1) 디코더가 이전에 예측한 단어만 다음 입력으로 사용
- 2) 학습 중 모델의 예측 대신 정답 단어를 디코더 입력으로 넣어 학습을 안정화
- 3) 인코더를 제거
- 4) Beam Search를 사용하지 않는 것

22. Seq2Seq의 Bottleneck Problem은 무엇인가?

- 1) 입력 전체를 고정 길이 벡터 하나에 압축해 정보 손실이 발생하는 문제
- 2) 출력 길이가 항상 1이 되는 문제
- 3) 파라미터가 너무 적은 문제
- 4) 단어 사전이 없는 문제

23. Attention의 핵심 아이디어는?

- 1) 디코더가 인코더의 모든 hidden state 중 필요한 부분에 가중치를 두고 직접 참조
- 2) 입력 문장을 한 벡터로만 압축
- 3) 모든 단어에 동일한 가중치 부여
- 4) 순서를 무작위로 섞기

24. Attention 계산 과정으로 가장 적절한 것은?

- 1) Query 와 Values 의 관계로 유사도 점수 계산 -> Softmax -> Values 가중합
- 2) 정답을 먼저 삭제 -> 평균 -> 분류
- 3) K-means -> PCA -> Softmax
- 4) Pooling -> Convolution -> RNN

25. Self-Attention 에서 Query, Key, Value 에 대한 설명으로 옳은 것은?

- 1) Query 는 찾고 싶은 정보, Key 는 정보의 특성, Value 는 실제 참조 내용
- 2) 세 벡터는 항상 서로 다른 문장에서만 온다.
- 3) Value 만 입력에서 만들고 나머지는 상수
- 4) Query 는 정답 라벨

26. Self-Attention 의 순서 정보 부재를 보완하기 위해 도입되는 것은?

- 1) Positional Encoding
- 2) Max Pooling
- 3) K-means
- 4) LOOCV

27. Decoder 의 미래 단어 참조 문제를 막기 위해 사용하는 것은?

- 1) Masked Self-Attention
- 2) Average Pooling
- 3) K-fold
- 4) Word2Vec

28. Transformer 의 Multi-Head Attention 을 사용하는 이유로 가장 적절한 것은?

- 1) 한 문장 관계를 여러 관점에서 동시에 파악하기 위해
- 2) 파라미터를 모두 제거하기 위해
- 3) 입력 길이를 1 로 만들기 위해
- 4) Attention 을 사용하지 않기 위해

29. Transformer 의 Encoder 와 Decoder 차이에 대한 설명으로 옳은 것은?

- 1) Encoder 는 양방향 문맥을 활용할 수 있고, Decoder 는 미래 토큰을 보지 않도록 masking 한다.
- 2) Encoder 만 next token 생성에 사용하고 Decoder 는 입력을 보지 않는다.
- 3) 둘 다 masking 이 필수적으로 동일하다.
- 4) Encoder 에는 attention 이 없다.

30. BERT, T5, GPT 의 구조적 구분으로 옳은 것은?

- 1) BERT=Encoder, T5=Encoder-Decoder, GPT=Decoder
- 2) BERT=Decoder, T5=Encoder, GPT=Encoder-Decoder
- 3) 세 모델 모두 CNN
- 4) 세 모델 모두 RNN 만 사용

PART 4 2-2. 텍스트 파운데이션 모델

1. 파운데이션 모델의 핵심 특징으로 가장 적절한 것은?

- 1) 태스크마다 항상 처음부터 별도 모델을 학습해야 한다.
- 2) 대규모 데이터를 폭넓게 학습한 뒤 다양한 태스크에 적응한다.
- 3) 규칙 기반 시스템만을 의미한다.
- 4) 텍스트만 처리할 수 있다.

2. 교안에서 파운데이션 모델의 구성 요소로 제시한 3 가지 조합은?

- 1) 빅데이터, 자기지도학습, Attention 기반 Transformer
- 2) 작은 데이터, 규칙 기반, K-means
- 3) 회귀, 분류, PCA
- 4) CNN, RNN, SVM

3. Scaling Law 의 의미로 가장 적절한 것은?

- 1) 모델을 작게 할수록 항상 성능이 좋아진다.
- 2) 더 많은 데이터, 더 큰 모델, 더 긴 학습이 성능 향상과 연결되는 경향
- 3) 학습률을 항상 1 로 고정
- 4) 모든 모델의 크기를 동일하게 맞춤

4. Emergent Property(창발성)의 의미로 가장 적절한 것은?

- 1) 모델 크기가 커지면 파라미터가 사라지는 현상
- 2) 특정 규모를 넘어서면 이전에 두드러지지 않던 능력이 갑자기 나타나는 현상
- 3) 모델이 무조건 오버피팅되는 현상
- 4) 입력 토큰이 모두 같은 벡터가 되는 현상

5. In-Context Learning 의 의미는?

- 1) 가중치를 반드시 업데이트해야만 새로운 태스크를 수행
- 2) 프롬프트 안의 설명과 예시만으로 새로운 태스크 패턴을 따라 수행
- 3) 모든 출력을 임의 생성
- 4) 이미지만을 학습

6. 거대언어모델의 기본 사전학습 방식으로 교안에서 강조한 것은?

- 1) 다음 토큰 예측
- 2) K-means
- 3) 이미지 분할
- 4) 선형회귀

7. 다음 토큰 예측만으로 학습한 거대언어모델의 한계로 교안에서 제시한 것은?

- 1) 사람의 지시를 잘 따르지 않거나 유해한 응답을 만들 수 있음
- 2) 텍스트를 생성할 수 없음
- 3) 확률분포를 출력할 수 없음
- 4) 파라미터가 업데이트되지 않음

8. Instruction Tuning 의 목적은?

- 1) 지시에 대해 어떤 응답을 생성해야 하는지 학습
- 2) 모델의 이미지를 분할
- 3) 클러스터 수를 결정
- 4) 학습 데이터를 모두 삭제

9. SFT(Supervised Fine-Tuning)와 교안에서 동일한 맥락으로 설명된 것은?

- 1) 지시 학습
- 2) K-fold
- 3) Beam Search
- 4) Top-P

10. Preference Learning 의 핵심은?

- 1) 여러 응답 중 사람이 더 선호하는 응답을 생성하도록 학습
- 2) 항상 하나의 정답 라벨만 사용
- 3) 출력을 확률로 만들지 않음
- 4) 모델 크기를 줄이는 것만 수행

11. RLHF 과정에서 Reward Model 의 역할은?

- 1) 사람의 선호와 유사한 보상 점수를 출력하도록 학습
- 2) 입력을 토큰화하지 않도록 함
- 3) 이미지를 생성
- 4) K-means 중심을 계산

12. Greedy Decoding 의 특징으로 옳은 것은?

- 1) 매 단계 가장 확률이 높은 토큰을 선택
- 2) 항상 K 개의 문장을 동시에 유지
- 3) 확률과 무관하게 완전 무작위
- 4) 미래 토큰을 먼저 생성

13. Beam Search 의 핵심 아이디어는?

- 1) 가장 확률 높은 하나만 유지
- 2) 확률이 높은 k 개의 후보를 동시에 유지하며 탐색
- 3) 모든 후보를 삭제
- 4) temperature 만 조절

14. Sampling 방식의 장점으로 가장 적절한 것은?

- 1) 항상 동일한 응답을 생성
- 2) 확률에 비례해 무작위 선택하므로 다양한 응답을 만들 수 있음
- 3) 계산 비용이 0
- 4) 정답을 보장

15. Temperature $T > 1$ 일 때 교안이 설명한 효과는?

- 1) 확률분포를 더 smooth 하게 해 다양한 응답 가능성을 높임
- 2) 확률분포를 더 sharp 하게 해 상위 토큰에만 집중
- 3) 모든 토큰 확률을 0 으로 만듦
- 4) Beam size 를 1 로 고정

16. Temperature $T < 1$ 일 때의 효과는?

- 1) 더 높은 확률의 응답에 집중
- 2) 무작위성이 무한히 증가
- 3) 모든 토큰 확률이 같아짐
- 4) 모델 파라미터가 감소

17. Top-K Sampling 의 특징은?

- 1) 누적 확률 P 만 사용
- 2) 확률이 높은 K 개의 토큰을 후보로 제한한 뒤 그 안에서 샘플링
- 3) 가장 낮은 확률 토큰만 사용
- 4) 모든 어휘를 동일 확률로 선택

18. Top-P(Nucleus) Sampling 의 특징은?

- 1) 후보 개수 K 를 항상 고정
- 2) 누적 확률 P 를 기준으로 후보 집합 크기를 동적으로 정함
- 3) 오직 가장 확률 높은 하나만 사용
- 4) 확률분포를 사용하지 않음

19. Prompt Engineering 의 의미는?

- 1) 모델 파라미터를 직접 수정하는 것만 의미
- 2) 원하는 답을 얻기 위해 지시와 예시 등 입력 프롬프트를 설계·조정하는 것
- 3) 훈련 데이터를 군집화
- 4) 모델의 GPU 를 교체

20. Chain-of-Thought(CoT) Prompting 의 핵심 아이디어는?

- 1) 질문만 짧게 제시
- 2) 예시에 추론 과정을 포함해 단계적 문제 해결을 유도
- 3) 모든 답을 한 단어로 제한
- 4) 모델의 attention 을 제거

21. Zero-shot CoT 의 의미로 가장 적절한 것은?

- 1) 추론 예시를 반드시 여러 개 제공
- 2) 별도의 few-shot 추론 예시 없이도 추론 단계를 생성하도록 지시
- 3) fine-tuning 후에만 작동
- 4) 이미지 전용 기법

22. 평가(Evaluation)의 3 요소로 교안에서 제시한 것은?

- 1) 목표, 평가 방법, 평가 지표
- 2) 학습률, 배치, 에폭
- 3) 입력, 은닉층, 출력
- 4) 정밀도, 재현율, F1 만

23. 정답이 정해져 있는 LLM 태스크의 대표적 평가 방식은?

- 1) 정확도 등 정답과 예측의 일치도
- 2) 오직 사람이 느끼는 감정
- 3) 항상 PPL 만
- 4) 클러스터링

24. Perplexity(PPL)가 주로 측정하려는 것은?

- 1) 문장이 모델 확률 관점에서 얼마나 자연스러운지
- 2) 이미지 해상도
- 3) 분류기의 FP 개수
- 4) 모델 파라미터 수

25. LLM-as-a-Judge 의 의미는?

- 1) 다른 거대언어모델을 이용해 생성 텍스트를 평가
- 2) 사람 평가를 절대 사용할 수 없다는 뜻
- 3) 훈련 데이터를 생성하는 과정만 의미
- 4) 항상 정확도만 계산

26. LLM-as-a-Judge 의 위치 편향(position bias)을 완화하는 방법으로 교안이 제시한 것은?

- 1) 응답 순서를 바꿔 두 번 평가 후 평균
- 2) 항상 첫 번째 답만 선택
- 3) 길이를 두 배로 늘림
- 4) temperature 를 0 으로 고정

27. LLM-as-a-Judge 의 길이 편향(length bias)은?

- 1) 품질과 무관하게 긴 응답을 더 선호할 수 있는 현상
- 2) 짧은 응답을 반드시 더 선호
- 3) 모델 입력 길이가 항상 1 인 현상
- 4) 출력 토큰 수를 계산하지 못하는 현상

28. 거대언어모델의 환각(Hallucination)에 대한 설명으로 옳은 것은?

- 1) 사실과 다른 내용을 사실처럼 유창하고 자신 있게 생성하는 현상
- 2) GPU 가 과열되는 현상
- 3) 모델이 정답만 말하는 현상
- 4) 토큰화를 하지 않는 현상

29. 교안에서 환각 완화 방법으로 제시한 것은?

- 1) RAG(검색 증강)
- 2) 무조건 더 높은 Temperature
- 3) 모든 입력 삭제
- 4) K-means

30. Synthetic Data(합성 데이터)의 활용에 대한 설명으로 옳은 것은?

- 1) 사람이 만든 데이터만 사용할 수 있다.
- 2) LLM 이 지시-응답 데이터를 생성해 학습 데이터 부족을 보완하는 데 사용할 수 있다.
- 3) 합성 데이터는 모델 학습에 사용할 수 없다.
- 4) 항상 실제 데이터보다 품질이 높다.

PART 5 3-1. 딥러닝 & 영상모델

1. FCN(Fully-Connected Network)으로 32x32x3 이미지를 처리하는 방식으로 교안이 설명한 것은?

- 1) 이미지의 3 차원 구조를 그대로 유지
- 2) 이미지를 1 차원 벡터로 펼쳐 입력
- 3) 이미지를 토큰 1 개로만 사용
- 4) 항상 5x5 필터로 처리

2. CNN의 합성곱 레이어 역할로 가장 적절한 것은?

- 1) 이미지를 필터와 연산해 특징 맵을 추출
- 2) 모든 이미지를 1 차원으로만 변환
- 3) 라벨을 무작위 생성
- 4) 학습률을 자동 계산

3. CNN이 FCN과 다른 점으로 옳은 것은?

- 1) CNN은 이미지의 공간 구조를 유지하면서 연산할 수 있다.
- 2) CNN에는 가중치가 없다.
- 3) FCN만 이미지에 사용할 수 있다.
- 4) CNN은 필터를 사용하지 않는다.

4. 합성곱 필터가 1개일 때 일반적으로 생성되는 특징 맵 수는?

- 1) 0개
- 2) 1개
- 3) 입력 채널 수와 항상 동일
- 4) 무한개

5. 입력 해상도 32, 커널 크기 5, 패딩 0, 스트라이드 1일 때 출력 해상도는?

- 1) 26
- 2) 27
- 3) 28
- 4) 32

6. Padding을 사용하는 주요 목적 중 하나는?

- 1) 출력 공간 크기를 조절하거나 유지하기 위해
- 2) 모델 파라미터를 모두 제거하기 위해
- 3) 라벨을 생성하기 위해
- 4) 필터 수를 항상 1로 만들기 위해

7. CNN 레이어를 여러 층 쌓을수록 얻을 수 있는 효과로 가장 적절한 것은?

- 1) 더 고차원적이고 복잡한 특징을 학습
- 2) 항상 입력 크기가 커짐
- 3) 비선형성이 사라짐
- 4) 필터가 필요 없어짐

8. CNN의 Receptive Field(수용영역)의 의미는?

- 1) 모델이 한 출력에서 영향을 받을 수 있는 입력 영역의 크기
- 2) 입력 이미지의 파일 크기
- 3) 클래스 개수
- 4) 학습률 범위

9. 네트워크가 깊어질수록 수용영역은 일반적으로 어떻게 되는가?

- 1) 넓어질 수 있다.
- 2) 항상 1 픽셀로 줄어든다.
- 3) 변하지 않는다.
- 4) 정의할 수 없다.

10. Pooling의 주요 목적 중 하나는?

- 1) 공간 해상도를 줄여 연산량을 낮춤
- 2) 채널을 항상 0으로 만듦
- 3) 출력 클래스 수를 증가
- 4) 패딩을 제거

11. Max Pooling은 어떻게 동작하는가?

- 1) 영역 내 최댓값 선택
- 2) 영역 내 최솟값 선택
- 3) 영역 내 모든 값을 0으로
- 4) 필터 가중치를 학습해 합성곱

12. Stride Convolution 의 특징으로 옳은 것은?

- 1) 필터를 S 칸씩 이동하여 공간 해상도를 줄일 수 있다.
- 2) 항상 1 칸만 이동
- 3) 학습 가능한 필터가 없다.
- 4) 이미지 크기를 키우는 연산만 수행

13. Pooling 과 Strided Convolution 의 차이로 교안이 강조한 것은?

- 1) Pooling 은 학습 파라미터가 없고 Strided Convolution 은 필터를 학습한다.
- 2) Pooling 만 해상도를 줄일 수 있다.
- 3) Strided Convolution 에는 커널이 없다.
- 4) 두 연산은 항상 완전히 동일하다.

14. AlexNet 의 모델 구조에 대한 설명으로 옳은 것은?

- 1) 5 개 합성곱 계층과 3 개 FC 계층
- 2) 합성곱 없이 FC 만 8 개
- 3) Transformer encoder 만 사용
- 4) RNN 만 사용

15. VGGNet 의 디자인 철학으로 옳은 것은?

- 1) 작고 단순한 3x3 필터를 깊게 쌓는다.
- 2) 11x11 필터 하나만 사용한다.
- 3) Pooling 을 전혀 사용하지 않는다.
- 4) FCN 없이 RNN 만 사용한다.

16. VGG 에서 3x3 합성곱 2 개를 연속 적용하는 장점으로 교안이 설명한 것은?

- 1) 5x5 하나와 유사한 수용영역을 가지면서 더 적은 연산량을 확보
- 2) 항상 해상도를 2 배 증가
- 3) 비선형성을 제거
- 4) 채널 수를 1 로 고정

17. ResNet 이 해결하려 한 문제로 교안에서 강조한 것은?

- 1) 깊이를 늘릴수록 오히려 성능이 나빠질 수 있는 degradation problem
- 2) 이미지에 순서가 없는 문제
- 3) 원-핫 차원의 저주
- 4) K-means 초기값 문제

18. ResNet 의 기본 Residual Block 출력 형태는?

- 1) $F(x)+x$
- 2) $F(x)-x$
- 3) $F(x)/x$
- 4) x 만

19. Residual/Skip Connection 의 핵심 아이디어로 가장 적절한 것은?

- 1) 입력 정보를 지름길로 후속 층에 직접 전달
- 2) 모든 중간 출력을 삭제
- 3) 필터를 공유하지 않음
- 4) 출력값을 항상 0 으로

20. MobileNet 의 핵심 효율화 아이디어는?

- 1) 공간 합성곱과 채널 결합을 depthwise 와 pointwise 단계로 분리
- 2) FC 레이어를 무한히 증가
- 3) 모든 커널을 11x11 로 확대
- 4) RNN 으로 이미지 처리

21. CNN 의 한계로 교안에서 제시한 것은?

- 1) 순서가 중요한 시퀀스 데이터를 직접 다루기 어렵고 긴 거리 의존성에 약함
- 2) 지역적 특징을 전혀 추출하지 못함
- 3) 이미지 분류에 사용할 수 없음
- 4) 가중치 공유를 하지 않음

22. RNN 이 CNN 과 달리 순차 데이터에서 사용하는 핵심 구조는?

- 1) 이전 단계의 hidden state 를 다음 단계로 전달
- 2) 모든 입력을 동시에 무순서 처리
- 3) Pooling 만 반복
- 4) Patch embedding 만 사용

23. 긴 시퀀스에서 단순 RNN 의 대표적 문제는?

- 1) 기울기 소실 또는 폭발
- 2) 이미지 해상도 증가
- 3) 필터 수가 0 이 됨
- 4) 클러스터 개수 증가

24. LSTM 이 단순 RNN 보다 긴 정보를 유지하도록 돕는 구성은?

- 1) Cell state 와 gate
- 2) Max pooling 만
- 3) K-means centroid
- 4) Residual block 만

25. Attention 에서 Query, Key, Value 의 관계로 가장 적절한 것은?

- 1) Query 와 Key 의 유사도를 계산해 Value 를 가중합
- 2) Query 와 Value 만 더하고 Key 는 사용하지 않음
- 3) 세 벡터는 모두 라벨
- 4) Query 는 항상 이미지 크기

26. Self-Attention 과 Cross-Attention 의 차이로 옳은 것은?

- 1) Self-Attention 은 Q/K/V 가 같은 입력에서, Cross-Attention 은 서로 다른 입력에서 올 수 있다.
- 2) Self-Attention 에는 Query 가 없다.
- 3) Cross-Attention 은 유사도를 계산하지 않는다.
- 4) 둘은 항상 완전히 같은 데이터만 사용한다.

27. ViT 에서 Positional Encoding 이 필요한 이유는?

- 1) Attention 만으로는 패치의 순서/위치 정보가 부족하기 때문
- 2) 이미지 채널을 0 으로 만들기 위해
- 3) 필터를 생성하기 위해
- 4) 모델을 CNN 으로 바꾸기 위해

28. 교안의 ViT 와 ResNet 비교에 대한 설명으로 옳은 것은?

- 1) ViT 가 모든 데이터 규모에서 항상 ResNet 보다 우수
- 2) ViT 는 대규모 데이터 사전학습 시 강점을 보일 수 있다.
- 3) ViT 는 attention 을 사용하지 않는다.
- 4) ResNet 은 이미지에 사용할 수 없다.

29. 지식 종류 방식에서 Teacher-Student 관계로 옳은 것은?

- 1) 학생 모델이 선생님 모델의 예측을 따라 배우도록 학습
- 2) 선생님 모델이 학생의 무작위 출력을 따라 학습
- 3) 두 모델은 서로 무관
- 4) 정답 라벨은 사용할 수 없음

30. Swin Transformer 의 핵심 아이디어로 교안에서 설명한 것은?

- 1) 윈도우 내부 attention 과 shifted window 를 활용해 전역 정보를 점진적으로 연결
- 2) 이미지 전체에 항상 하나의 1x1 attention 만 수행
- 3) RNN hidden state 만 사용
- 4) Pooling 을 사용하지 않는 것만이 핵심

PART 6 3-2. 이미지 파운데이션 모델

1. 교안에서 설명한 파운데이션 모델의 정의로 가장 적절한 것은?

- 1) 대규모 데이터를 폭넓게 학습한 후 다양한 문제에 빠르게 적응하는 범용 대형 AI 모델
- 2) 한 태스크에만 쓰는 작은 규칙 기반 모델
- 3) 라벨이 없는 데이터에만 쓰는 군집 모델
- 4) 이미지 입력을 받을 수 없는 모델

2. Zero-shot 의 의미는?

- 1) 예시 없이 사전학습된 능력만으로 새로운 문제를 수행
- 2) 예시를 반드시 10 개 제공
- 3) 가중치를 추가 학습
- 4) 모델을 처음부터 재학습

3. Few-shot 의 의미는?

- 1) 예시 몇 개를 함께 제시해 패턴을 따라 문제를 수행
- 2) 모델의 weight 를 모두 초기화
- 3) 모든 데이터를 라벨링
- 4) 출력만 학습

4. Fine-tuning 의 특징으로 옳은 것은?

- 1) 모델 weight 가 실제로 업데이트된다.
- 2) 추가 학습 없이 프롬프트만 바꾼다.
- 3) 예시를 보여주는 것만 의미한다.
- 4) 사전학습 모델을 사용할 수 없다.

5. 컴퓨터 비전 파운데이션 모델이 수행할 수 있는 작업으로 교안에 포함된 것은?

- 1) 분할, 탐지, 깊이/3D 예측
- 2) 오직 선형회귀
- 3) 오직 텍스트 번역
- 4) K-means 만

6. CLIP 의 핵심 목적은?

- 1) 이미지와 텍스트 사이의 의미적 유사도를 학습
- 2) 이미지의 픽셀만 복원
- 3) 텍스트만 생성
- 4) 클러스터 수 결정

7. CLIP 의 기본 인코더 구성으로 옳은 것은?

- 1) 이미지 인코더 + 텍스트 인코더
- 2) RNN 하나만
- 3) K-means + PCA
- 4) Decoder 하나만

8. CLIP 이미지 인코더에 사용될 수 있다고 교안에 제시된 모델은?

- 1) ViT 또는 ResNet
- 2) LSTM 만
- 3) K-means
- 4) Logistic Regression 만

9. CLIP 의 대조학습(contrastive learning) 목표로 가장 적절한 것은?

- 1) 맞는 이미지-텍스트 쌍은 가깝게, 맞지 않는 쌍은 멀게
- 2) 모든 임베딩을 같은 위치로
- 3) 텍스트만 멀게
- 4) 정답과 오답을 구분하지 않음

10. 멀티모달 정합(Multi-modal Matching)의 의미는?

- 1) 서로 다른 모달리티를 공통 임베딩 공간에서 연결
- 2) 모달리티를 무작위로 섞음
- 3) 이미지를 항상 텍스트로 직접 생성
- 4) 텍스트를 제거

11. 교안에서 CLIP 이 이미지와 텍스트 임베딩 유사도를 확인하는 방법으로 언급한 것은?

- 1) 코사인 유사도
- 2) MSE 만
- 3) Accuracy 만
- 4) IoU 만

12. SigLIP 이 CLIP 과 다른 점으로 교안에서 강조한 것은?

- 1) Softmax 대신 sigmoid 기반 손실함수를 사용
- 2) 이미지 인코더를 사용하지 않음
- 3) 텍스트를 처리하지 않음
- 4) 항상 RNN 만 사용

13. LLaVA 의 기본 구조로 가장 적절한 것은?

- 1) Vision encoder 와 Language model 을 연결한 멀티모달 모델
- 2) CNN 하나만 사용하는 분류기
- 3) K-means 기반 모델
- 4) 오디오 전용 모델

14. LLaVA 의 Step 1 사전학습 단계에서 교안이 설명한 핵심은?

- 1) 이미지 표현을 언어 모델이 사용할 수 있는 표현으로 연결하는 선형 레이어를 학습
- 2) 언어 모델을 삭제
- 3) 모든 파라미터를 처음부터 재학습
- 4) 이미지 라벨만 K-means 로 생성

15. LLaVA 학습 데이터에 대한 설명으로 옳은 것은?

- 1) GPT 를 활용해 시각 설명 등의 합성 데이터를 생성할 수 있다.
- 2) 합성 데이터는 절대 사용하지 않는다.
- 3) 오직 오디오 데이터만 사용
- 4) 라벨 없는 숫자 데이터만 사용

16. Hugging Face 의 역할로 가장 적절한 것은?

- 1) AI 오픈소스 모델과 데이터셋을 공유하고 사용할 수 있는 플랫폼
- 2) 이미지 편집 전용 데스크톱 앱
- 3) 오직 하드웨어 판매 서비스
- 4) K-fold 계산기

17. Gradio 의 역할로 교안에서 설명한 것은?

- 1) 머신러닝 모델을 웹 인터페이스로 쉽게 배포할 수 있게 지원
- 2) 모델을 군집화
- 3) GPU 드라이버를 교체
- 4) 이미지를 토큰화

18. 모델 서빙(model serving)의 의미로 가장 적절한 것은?

- 1) 학습된 모델을 서비스 환경에서 실행하고 사용자 입력에 예측 결과를 제공하는 절차
- 2) 데이터를 훈련셋으로만 나누는 것
- 3) 모델을 삭제하는 것
- 4) 오직 로컬 파일 저장

19. sVLM 이 등장한 주요 동기로 가장 적절한 것은?

- 1) VLM 을 더 작고 가볍게 만들어 모바일/엣지 기기에서 활용
- 2) 모델을 더 무겁게만 만들기 위해
- 3) 이미지 입력을 제거
- 4) 텍스트만 분류

20. 비영어권 언어의 토큰화 문제로 교안에서 제시한 내용은?

- 1) 동일한 문장도 언어에 따라 토큰 길이가 크게 달라질 수 있다.
- 2) 모든 언어는 항상 토큰 수가 같다.
- 3) 한국어는 토큰화가 필요 없다.
- 4) 형태론이 풍부한 언어는 항상 더 짧게 토큰화된다.

21. Fine-tuning 의 장점으로 교안이 제시한 것이 아닌 것은?

- 1) 적은 데이터로 특정 작업에 특화 가능
- 2) 학습 리소스를 절약할 수 있음
- 3) 프롬프트보다 결과 품질이 좋아질 수 있음
- 4) 모델 weight 는 절대로 바뀌지 않음

22. PEFT(Parameter-Efficient Fine-Tuning)가 필요한 이유는?

- 1) 파운데이션 모델이 너무 커 전체 파라미터 미세조정 비용이 크기 때문
- 2) 파운데이션 모델에는 파라미터가 없기 때문
- 3) 이미지를 사용할 수 없기 때문
- 4) 클러스터링만 가능하기 때문

23. Prompt Design 의 특징으로 옳은 것은?

- 1) 추가 학습 없이 입력 텍스트를 설계해 원하는 출력에 가깝게 유도
- 2) 모든 모델 파라미터를 업데이트
- 3) 가상 토큰만 학습
- 4) Adapter 를 반드시 추가

24. Prompt Tuning 의 특징으로 옳은 것은?

- 1) 가상 토큰의 임베딩만 학습하고 사전학습 모델은 고정할 수 있다.
- 2) 전체 모델을 반드시 처음부터 학습
- 3) 사람이 프롬프트를 전혀 사용할 수 없다.
- 4) 이미지 필터만 학습

25. Adapter 방식의 핵심은?

- 1) 작은 모듈을 네트워크에 추가해 일부만 학습
- 2) 모델 전체를 삭제
- 3) 출력을 항상 0 으로
- 4) 학습 데이터를 사용하지 않음

26. Knowledge Distillation 의 목적은?

- 1) 고성능 큰 모델의 지식을 더 작은 모델에 압축
- 2) 학생 모델을 더 크게만 만들기
- 3) 정답 라벨을 제거
- 4) 모델을 비지도 군집화

27. 지식증류에서 soft-label 의 의미는?

- 1) 선생님 모델의 0~1 사이 예측 확률을 가짜 라벨처럼 사용
- 2) 항상 정수 0 하나
- 3) 입력 이미지 크기
- 4) 학습률

28. Segment Anything Model(SAM)의 대표 기능은?

- 1) 사용자 클릭 등의 프롬프트를 받아 원하는 영역의 마스크를 추출
- 2) 텍스트 번역
- 3) 음성 합성
- 4) 회귀계수 추정

29. Grounding DINO 의 대표 기능은?

- 1) 텍스트 입력을 이용해 이미지 내 물체를 탐지
- 2) 오디오를 텍스트로 변환
- 3) 문장 요약
- 4) K-means 군집

30. AnomalyGPT 와 같은 제조업 특화 모델의 활용으로 가장 적절한 것은?

- 1) 이미지의 결함/불량 탐지와 질의응답
- 2) 소셜 생성만
- 3) 추가 회귀만
- 4) 클러스터 개수 결정만

정답 및 해설

문제를 모두 푼 뒤 확인하세요.

1-1. AI & 기계학습 기초 - 정답표

1	2	3	4	5	6	7	8	9	10
2	2	1	2	2	2	3	3	2	2
11	12	13	14	15	16	17	18	19	20
2	1	2	3	2	1	1	2	2	2
21	22	23	24	25	26	27	28	29	30
2	2	2	2	2	3	2	2	2	3

간단 해설

1. 정답 2 | 교안에서는 ML 을 AI 범주 내에서 데이터로부터 학습하여 목적을 달성하는 접근 방법론으로 설명한다.
2. 정답 2 | Feature 는 모델이 예측에 사용하는 정보이며 판단의 근거가 된다.
3. 정답 1 | Label 은 모델이 예측하려는 목표값 또는 정답이다.
4. 정답 2 | 가설공간은 입력과 출력의 관계를 표현할 수 있는 후보 함수들의 집합이다.
5. 정답 2 | 학습은 데이터와 성능척도를 바탕으로 가설공간에서 적절한 모델을 선택하는 과정이다.
6. 정답 2 | 1D 는 하나의 피처를 사용하는 학습을 뜻한다.
7. 정답 3 | 교안은 측정오차 ϵ 를 X 와 독립이며 평균이 0 이라고 가정한다.
8. 정답 3 | 회귀는 연속적인 수치값을 예측하는 문제이다.
9. 정답 2 | MSE 는 정답과 예측값의 차이를 제곱해 평균하므로 큰 오차에 더 큰 패널티를 준다.
10. 정답 2 | RMSE 는 MSE 의 제곱근이므로 원래 데이터와 같은 단위로 해석할 수 있다.
11. 정답 2 | R^2 는 평균 예측과 비교한 설명력을 나타내며 일반적으로 1 에 가까울수록 설명력이 높다.
12. 정답 1 | 모델이 단순 평균 예측보다도 못하면 R^2 가 음수가 될 수 있다.
13. 정답 2 | 예를 들어 양성 1%, 음성 99%에서 모두 음성으로 예측해도 99% 정확도가 될 수 있다.
14. 정답 3 | FP(False Positive)는 실제 음성인데 양성으로 잘못 예측한 오탐이다.
15. 정답 2 | Precision 은 양성이라고 판정한 것 가운데 진짜 양성의 비율이다.
16. 정답 1 | Recall 은 실제 양성 가운데 얼마나 많이 찾아냈는지를 나타낸다.
17. 정답 1 | F1-score 는 정밀도와 재현율을 함께 고려하는 조화평균 지표이다.
18. 정답 2 | 교안은 학습의 목적을 테스트 예측, 즉 일반화 오차의 최소화로 설명한다.
19. 정답 2 | 오버피팅은 훈련 데이터의 우연한 패턴과 잡음까지 학습해 일반화가 나빠지는 현상이다.
20. 정답 2 | 분포 변화는 환경, 계절, 센서 변경 등으로 훈련과 실제 분포가 달라지는 현상이며 오버피팅과 구분된다.
21. 정답 2 | 언더피팅은 모델이 너무 단순하거나 학습이 덜 되어 중요한 패턴을 잡지 못하는 경우이다.
22. 정답 2 | 같은 데이터에 다시 적용한 훈련 오차는 새 데이터의 테스트 오차보다 낮게 나오는 경우가 많다.
23. 정답 2 | Hold-out 은 일부를 훈련에, 나머지를 검증에 사용해 일반화 성능을 추정한다.
24. 정답 2 | 한 번의 임의 분할은 어떤 샘플이 어느 쪽에 들어갔는지에 따라 결과가 불안정할 수 있다.
25. 정답 2 | K-fold 는 K 개의 폴드를 번갈아 검증셋으로 사용하고 K 번의 평가값을 평균한다.
26. 정답 3 | LOOCV 는 매번 관측치 하나만 검증으로 두고 나머지 전부를 훈련에 사용한다.
27. 정답 2 | 특성 선택에서 라벨을 사용한다면 그 단계도 훈련 과정이므로 각 폴드 안에서 수행해야 데이터 누수를 막을 수 있다.
28. 정답 2 | 비지도학습은 정답 라벨 없이 데이터의 구조, 패턴, 잠재 집단 등을 찾는다.
29. 정답 2 | K-means 는 각 군집 내부의 흠어짐, 즉 within-cluster variation 의 합을 줄이는 방향으로 군집을 찾는다.
30. 정답 3 | 클러스터링에서는 변수 스케일의 영향이 크므로 표준화가 중요할 수 있고, K-means 는 초기값 및 계층적 군집은 링크 선택에 따라 결과가 달라질 수 있다.

1-2. AI & 기계학습 방법 - 정답표

1	2	3	4	5	6	7	8	9	10
1	2	2	2	3	2	1	2	1	2
11	12	13	14	15	16	17	18	19	20
2	2	2	1	1	2	2	1	1	2
21	22	23	24	25	26	27	28	29	30
1	2	1	1	2	2	2	2	1	2

간단 해설

- 정답 1 | 선형회귀는 반응변수 Y 가 설명변수들에 선형적으로 의존한다고 가정한다.
- 정답 2 | β_1 은 X 가 1 단위 변할 때 Y 가 평균적으로 얼마나 변하는지를 나타내는 기울기 계수이다.
- 정답 2 | 잔차는 실제값에서 예측값을 뺀 값이다.
- 정답 2 | 최소제곱법은 잔차제곱합 RSS 가 가장 작아지도록 회귀계수를 정한다.
- 정답 3 | RSS 는 각 관측치 잔차를 제곱해 모두 더한 값이다.
- 정답 2 | 교안의 광고 예시에서는 작은 p-value 를 근거로 관계가 없다는 귀무가설을 기각하였다.
- 정답 1 | R^2 는 반응변수 변동 중 모델이 설명하는 비율로 해석한다.
- 정답 2 | 다중선형회귀는 복수의 설명변수를 동시에 이용한다.
- 정답 1 | 다른 설명변수를 고정한 조건에서 X_j 의 1 단위 변화와 관련된 Y 의 평균 변화가 β_j 이다.
- 정답 2 | 선형회귀 출력은 제한이 없어 확률 범위인 0~1 을 벗어날 수 있다.
- 정답 2 | 로지스틱 함수는 입력값이 커지거나 작아져도 출력이 0~1 범위에 있게 한다.
- 정답 2 | 로지스틱 회귀는 최대우도추정(MLE)을 사용해 모수를 추정한다.
- 정답 2 | 교안은 은닉층이 1 개인 신경망을 Shallow Network 로 정의한다.
- 정답 1 | ReLU 는 음수 입력을 0 으로, 양수 입력을 그대로 통과시킨다.
- 정답 1 | 교안에서는 학습을 손실을 줄이도록 파라미터를 조정해 적절한 함수를 정하는 과정으로 설명한다.
- 정답 2 | ReLU 를 이용한 신경망은 여러 구간에서 각각 선형인 piecewise linear 형태를 만들 수 있다.
- 정답 2 | Hidden Unit 은 입력과 출력 사이에서 중간 계산을 수행하는 단위이다.
- 정답 1 | Hidden Unit 이 많아지면 piecewise linear 함수의 꺾임이 많아져 표현력이 증가한다.
- 정답 1 | 교안은 충분한 Hidden Unit 을 가진 Shallow NN 도 연속함수를 원하는 정밀도로 근사할 수 있음을 설명한다.
- 정답 2 | 교안에서는 여러 출력이 있어도 각 출력의 꺾이는 위치는 공유된 Hidden Unit 에 의해 정해진다고 설명한다.
- 정답 1 | 교안은 은닉층이 2 개 이상인 신경망을 Deep Network 로 정의한다.
- 정답 2 | 여러 층을 합성하면 단순히 같은 수의 Hidden Unit 을 한 층에 둔 것보다 더 복잡한 표현을 만들 수 있다.
- 정답 1 | 경사하강법은 손실함수를 파라미터에 대해 미분해 기울기를 계산하고 그 반대 방향으로 갱신한다.
- 정답 1 | 학습률은 한 번의 파라미터 업데이트에서 얼마나 크게 이동할지를 정한다.
- 정답 2 | 교안에서는 선형회귀 같은 Convex 문제는 전역 최소점이 유일해 최적화가 쉽다고 설명한다.
- 정답 2 | 신경망 학습은 대부분 Non-convex 문제로 여러 지역 최소점이 존재할 수 있다.
- 정답 2 | 교안의 SGD 는 한 번에 데이터 하나를 사용해 기울기를 계산하는 방식이다.
- 정답 2 | Mini-batch 는 일부 샘플을 묶어 계산하여 병렬 처리가 가능하고 SGD 보다 안정적이며 전체 배치보다 빠를 수 있다.
- 정답 1 | Epoch 은 전체 학습 데이터를 한 번 모두 사용한 학습 주기를 뜻한다.
- 정답 2 | 일부 데이터만 사용하면 기울기에 노이즈가 생기며, 이 노이즈가 지역 최소점에서 빠져나오는 데 도움을 줄 수 있다고 설명한다.

2-1. 자연어 처리 기본 - 정답표

1	2	3	4	5	6	7	8	9	10
2	4	2	2	2	4	2	1	1	1
11	12	13	14	15	16	17	18	19	20
2	2	1	1	1	1	1	1	1	1
21	22	23	24	25	26	27	28	29	30
2	1	1	1	1	1	1	1	1	1

간단 해설

1. 정답 2 | 원-핫 벡터는 해당 단어 위치만 1 이고 나머지는 모두 0 인 희소 표현이다.
2. 정답 4 | 밀집 벡터로 의미 관계를 반영하는 것은 원-핫의 장점이 아니라 워드 임베딩의 장점이다.
3. 정답 2 | 워드 임베딩은 유사한 단어가 벡터 공간에서 가깝게 위치하도록 의미 관계를 반영한다.
4. 정답 2 | Skip-gram 은 중심 단어가 주어졌을 때 주변 단어들을 예측한다.
5. 정답 2 | CBOW 는 주변 문맥 단어들을 사용해 중심 단어를 맞춘다.
6. 정답 4 | 순차 데이터는 순서가 바뀌면 의미가 달라질 수 있다.
7. 정답 2 | RNN 은 이전 정보를 hidden state 에 담아 다음 시점으로 전달한다.
8. 정답 1 | 현재 hidden state 는 이전 hidden state 와 현재 입력을 함께 사용해 갱신된다.
9. 정답 1 | RNN 은 시간축의 각 단계에 동일한 가중치를 공유해 파라미터 효율적이다.
10. 정답 1 | 기울기 소실은 반복적인 곱셈으로 기울기가 매우 작아져 장기 의존성 학습이 어려워지는 문제이다.
11. 정답 2 | 기울기 폭발은 큰 값이 반복 곱해지며 기울기가 지나치게 커지는 현상이다.
12. 정답 2 | LSTM 은 RNN 의 장기 의존성 학습과 기울기 소실 문제를 개선하기 위해 제안되었다.
13. 정답 1 | Cell state 는 장기 정보를 유지하는 경로 역할을 한다.
14. 정답 1 | Forget gate 는 과거 정보 중 버릴 것과 유지할 것을 조절한다.
15. 정답 1 | Input gate 는 새 정보가 cell state 에 얼마나 반영될지 제어한다.
16. 정답 1 | Output gate 는 cell state 의 정보가 현재 hidden state 로 얼마나 나갈지 조절한다.
17. 정답 1 | 언어 모델은 문맥을 바탕으로 단어 시퀀스의 확률과 다음 단어의 확률을 모델링한다.
18. 정답 1 | N-gram 은 앞선 N-1 개 단어를 문맥으로 사용한다.
19. 정답 1 | Seq2Seq 는 입력을 요약하는 Encoder 와 출력을 생성하는 Decoder 로 구성된다.
20. 정답 1 | Encoder 는 입력 시퀀스의 정보를 내부 표현으로 압축한다.
21. 정답 2 | Teacher Forcing 은 학습 초기에 정답 토큰을 디코더 입력으로 넣어 학습을 빠르고 안정적으로 한다.
22. 정답 1 | 초기 Seq2Seq 는 마지막 hidden state 하나에 모든 정보를 담으려 해 긴 문장에서 정보 손실이 발생할 수 있다.
23. 정답 1 | Attention 은 출력 시점마다 필요한 입력 부분에 더 집중하도록 가중합을 만든다.
24. 정답 1 | 교안은 유사도 점수를 계산하고 softmax 로 attention distribution 을 만든 뒤 Values 를 가중합해 context vector 를 만든다고 설명한다.
25. 정답 1 | Q/K/V 는 각 입력 토큰을 서로 다른 관점으로 변환한 벡터이며 Query-Key 유사도에 따라 Value 를 가중합한다.
26. 정답 1 | Self-Attention 자체는 위치 순서를 알지 못하므로 위치 벡터를 더해준다.
27. 정답 1 | 미래 위치의 attention score 를 차단해 생성 시점 이후 토큰을 볼 수 없게 한다.
28. 정답 1 | 여러 head 는 문법, 의미, 시제 등 서로 다른 관점의 관계를 동시에 학습할 수 있게 한다.
29. 정답 1 | Encoder 는 입력 전체의 양방향 문맥을 보고, Decoder 는 자동화귀 생성을 위해 미래 위치를 가린다.
30. 정답 1 | 교안은 BERT 를 Encoder 기반, T5 를 Encoder-Decoder 기반, GPT 를 Decoder 기반 모델로 구분한다.

2-2. 텍스트 파운데이션 모델 - 정답표

1	2	3	4	5	6	7	8	9	10
2	1	2	2	2	1	1	1	1	1
11	12	13	14	15	16	17	18	19	20
1	1	2	2	1	1	2	2	2	2
21	22	23	24	25	26	27	28	29	30
2	1	1	1	1	1	1	1	1	2

간단 해설

1. 정답 2 | 파운데이션 모델은 대규모 사전학습을 기반으로 여러 새로운 문제에 프롬프트나 추가 학습으로 적응하는 범용 모델이다.
2. 정답 1 | 교안은 빅데이터, self-supervised learning, attention 기반 Transformer 를 핵심 요소로 제시한다.
3. 정답 2 | 교안은 규모를 키울수록 성능이 좋아지는 경향을 Scaling Law 로 설명한다.
4. 정답 2 | 창발성은 일정 규모 이상에서 새로운 능력이 두드러지게 나타나는 특성을 의미한다.
5. 정답 2 | ICL 은 별도 fine-tuning 없이 컨텍스트의 지시와 예시를 통해 태스크를 수행하는 능력이다.
6. 정답 1 | GPT 계열 LLM 의 기본 사전학습은 다음 토큰 확률을 예측하는 자기지도학습 방식이다.
7. 정답 1 | 사전학습만으로는 사용자 의도와 가치에 정렬되지 않을 수 있어 alignment 학습이 추가된다.
8. 정답 1 | 다양한 지시-응답 쌍으로 지도 추가학습해 지시 수행 능력을 높인다.
9. 정답 1 | Instruction tuning 은 입력 지시와 정답 응답을 따라 하도록 지도 추가학습하는 SFT 형태로 설명된다.
10. 정답 1 | 선호 학습은 정답 하나가 아니라 응답들 사이의 사람 선호를 이용한다.
11. 정답 1 | 보상 모델은 사람이 어떤 응답을 더 좋아하는지 모방해 응답에 점수를 부여한다.
12. 정답 1 | Greedy 는 각 생성 단계에서 현재 확률이 가장 높은 다음 토큰 하나를 선택한다.
13. 정답 2 | Beam Search 는 누적 확률이 높은 여러 후보를 함께 유지해 더 나은 전체 시퀀스를 찾는다.
14. 정답 2 | Sampling 은 모델 확률분포에서 확률적으로 토큰을 뽑아 다양성을 높인다.
15. 정답 1 | 높은 temperature 는 확률분포를 평평하게 만들어 상대적으로 다양한 토큰이 선택될 수 있게 한다.
16. 정답 1 | 낮은 temperature 는 분포를 sharp 하게 만들어 높은 확률 토큰에 더 집중한다.
17. 정답 2 | Top-K 는 후보 토큰 수 K 를 고정한다.
18. 정답 2 | Top-P 는 누적 확률이 P 에 도달할 때까지 상위 토큰들을 후보로 포함한다.
19. 정답 2 | 프롬프트 엔지니어링은 모델 입력을 잘 설계해 출력 품질과 태스크 수행을 개선하는 방법이다.
20. 정답 2 | CoT 는 단순 정답뿐 아니라 문제 해결 과정의 예시를 제공해 추론을 유도한다.
21. 정답 2 | Zero-shot CoT 는 예시 없이도 단계적 추론을 유도하는 프롬프트 방식이다.
22. 정답 1 | 평가를 설계할 때 무엇을 달성할지, 어떤 방법으로 측정할지, 어떤 지표를 쓸지 구분한다.
23. 정답 1 | 객관식처럼 정답이 있는 경우에는 예측과 정답의 일치율을 사용할 수 있다.
24. 정답 1 | PPL 은 언어모델이 텍스트를 얼마나 자연스럽고 높은 확률로 설명하는지와 관련된 지표이다.
25. 정답 1 | 질의, 평가 대상 텍스트, 평가 기준을 LLM 에 주고 점수와 이유를 받는 방식이다.
26. 정답 1 | 응답 A/B 의 순서를 뒤집어 재평가하면 특정 위치에 대한 선호 영향을 줄일 수 있다.
27. 정답 1 | 교안은 LLM 평가자가 내용 품질과 별개로 긴 응답을 더 선호할 수 있다고 설명한다.
28. 정답 1 | 환각은 사실과 다르거나 지어낸 내용을 정확한 정보처럼 생성하는 문제이다.
29. 정답 1 | 외부 검색 결과를 근거로 답하도록 하는 RAG 가 환각 완화 수단으로 제시된다.
30. 정답 2 | 교안은 Self-Instruct 처럼 LLM 을 이용해 대량의 합성 지시 데이터를 만들고 필터링해 학습에 활용한 사례를 소개한다.

3-1. 딥러닝 & 영상모델 - 정답표

1	2	3	4	5	6	7	8	9	10
2	1	1	2	3	1	1	1	1	1
11	12	13	14	15	16	17	18	19	20
1	1	1	1	1	1	1	1	1	1
21	22	23	24	25	26	27	28	29	30
1	1	1	1	1	1	1	2	1	1

간단 해설

1. 정답 2 | FCN 은 32x32x3 이미지를 3072 차원의 1D 벡터로 변환해 입력한다.
2. 정답 1 | Convolution Layer 는 필터를 이동시키며 지역 영역과 내적해 feature map 을 만든다.
3. 정답 1 | CNN 은 이미지의 H/W 구조를 보존하면서 국소적인 필터 연산을 수행한다.
4. 정답 2 | 필터 하나는 하나의 출력 채널, 즉 하나의 특징 맵을 만든다.
5. 정답 3 | 교안의 기본식은 $32-5+1=28$ 이다.
6. 정답 1 | 패딩은 경계 주변에 값을 추가해 합성곱 후 공간 해상도를 원하는 크기로 조절한다.
7. 정답 1 | 깊은 층으로 갈수록 옛지 같은 단순 특징에서 더 복잡한 패턴으로 표현을 확장할 수 있다.
8. 정답 1 | 수용영역은 네트워크가 특정 출력 계산에서 볼 수 있는 입력 공간 영역이다.
9. 정답 1 | 여러 합성곱을 중첩하면 한 출력이 더 넓은 원본 입력 영역의 영향을 받는다.
10. 정답 1 | Pooling 은 값을 요약해 공간 크기를 줄이고 계산 효율 및 위치 변화에 대한 강건성을 높인다.
11. 정답 1 | 맥스 풀링은 커널 영역에서 가장 큰 값을 대표값으로 선택한다.
12. 정답 1 | 스트라이드가 1 보다 크면 필터가 더 큰 간격으로 이동해 출력 해상도가 줄어든다.
13. 정답 1 | 풀링은 정해진 요약 연산인 반면 스트라이드 합성곱은 다운샘플링과 동시에 필터를 학습한다.
14. 정답 1 | 교안은 AlexNet 을 5 Conv + 3 FC 의 8 계층 CNN 으로 소개한다.
15. 정답 1 | VGG 는 3x3 합성곱을 반복해 깊이를 늘리는 단순한 설계 규칙을 제시했다.
16. 정답 1 | 작은 커널을 여러 번 쌓으면 유사한 수용영역을 더 효율적으로 만들 수 있다.
17. 정답 1 | 단순히 층을 깊게 쌓을 때 학습 성능이 저하되는 degradation 문제를 residual connection 으로 완화했다.
18. 정답 1 | 변환 경로 $F(x)$ 에 입력 x 를 shortcut 으로 더한다.
19. 정답 1 | 입력 x 를 그대로 우회 전달해 깊은 네트워크에서도 정보와 기울기 흐름을 돕는다.
20. 정답 1 | MobileNet 은 depthwise convolution 과 1x1 pointwise convolution 으로 연산을 분리해 계산량을 줄인다.
21. 정답 1 | CNN 은 지역 패턴 추출에는 강하지만 순서와 멀리 떨어진 요소 관계를 직접 모델링하는 데 한계가 있다.
22. 정답 1 | RNN 은 이전 상태를 다음 단계로 넘겨 시간/순서 정보를 반영한다.
23. 정답 1 | 반복적인 가중치 곱으로 역전파 기울기가 매우 작아지거나 커질 수 있다.
24. 정답 1 | Cell state 에 정보를 보존하고 게이트로 흐름을 제어해 장기 의존성을 다룬다.
25. 정답 1 | Attention 은 query-key 관련도에 따라 value 정보를 결합한다.
26. 정답 1 | Self-Attention 은 한 입력 내부 관계를, Cross-Attention 은 서로 다른 모달리티나 인코더/디코더 사이 관계를 연결할 수 있다.
27. 정답 1 | 이미지 패치 토큰의 위치를 모델이 알 수 있도록 위치 벡터를 더한다.
28. 정답 2 | 교안은 ImageNet 만으로는 ResNet 이 더 나을 수 있지만, ViT 가 대규모 사전학습 후 미세조정에서 강점을 보인다고 설명한다.
29. 정답 1 | 큰 Teacher 의 예측 정보를 작은 Student 가 모방하도록 학습해 성능을 전달한다.
30. 정답 1 | 지역 윈도우 attention 과 이동된 윈도우를 겹쳐 계산 효율과 전역 연결을 함께 확보한다.

3-2. 이미지 파운데이션 모델 - 정답표

1	2	3	4	5	6	7	8	9	10
1	1	1	1	1	1	1	1	1	1
11	12	13	14	15	16	17	18	19	20
1	1	1	1	1	1	1	1	1	1
21	22	23	24	25	26	27	28	29	30
4	1	1	1	1	1	1	1	1	1

간단 해설

1. 정답 1 | 파운데이션 모델은 폭넓은 사전학습을 바탕으로 여러 다운스트림 태스크에 적응하는 범용 모델이다.
2. 정답 1 | Zero-shot 은 예시 없이 질문/지시만으로 문제를 해결하는 방식이다.
3. 정답 1 | Few-shot 은 소수의 예시를 컨텍스트에 제공해 모델이 패턴을 적용하도록 한다.
4. 정답 1 | Fine-tuning 은 사전학습된 모델을 새 태스크 데이터로 추가 학습해 가중치를 조정한다.
5. 정답 1 | 비전 파운데이션 모델은 segmentation, detection, depth/3D 등 다양한 작업에 활용된다.
6. 정답 1 | CLIP 은 이미지와 자연어를 공통 임베딩 공간에 정렬해 유사도를 학습한다.
7. 정답 1 | CLIP 은 이미지 인코더와 Transformer 기반 텍스트 인코더의 두 타워 구조를 사용한다.
8. 정답 1 | 교안은 CLIP 이미지 인코더로 ViT-B 또는 ResNet50 을 제시한다.
9. 정답 1 | 대조학습은 양성 쌍의 임베딩은 끌어당기고 음성 쌍은 밀어낸다.
10. 정답 1 | 이미지와 텍스트처럼 다른 모달리티가 비교 가능한 공통 공간에 위치하도록 학습한다.
11. 정답 1 | CLIP 은 공통 공간의 이미지/텍스트 임베딩 간 코사인 유사도를 이용한다.
12. 정답 1 | SigLIP 은 pairwise sigmoid loss 를 사용해 학습 효율과 안정성을 높이는 방식으로 소개된다.
13. 정답 1 | LLaVA 는 시각 인코더와 언어모델을 연결해 이미지 이해와 텍스트 생성을 결합한다.
14. 정답 1 | 초기 단계에서는 vision 표현과 language space 를 연결하는 projection/linear layer 중심으로 학습한다.
15. 정답 1 | 교안은 GPT 를 활용한 visual instruction 데이터 생성 사례를 제시한다.
16. 정답 1 | Hugging Face 는 pretrained model, dataset 등을 공유하고 사용할 수 있게 하는 플랫폼이다.
17. 정답 1 | Gradio 는 모델 데모/인터페이스를 빠르게 만들 수 있는 오픈소스 라이브러리이다.
18. 정답 1 | 서버는 배포, API 제공, 운영 보조 기능 등을 통해 모델 예측을 서비스로 제공하는 과정이다.
19. 정답 1 | sVLM 은 온디바이스 및 자원 제한 환경에서 실행 가능한 경량 Vision-Language Model 을 목표로 한다.
20. 정답 1 | 토큰라이저의 언어 편중과 형태적 차이 때문에 비영어권 언어는 같은 내용도 더 많은 토큰을 사용할 수 있다.
21. 정답 4 | Fine-tuning 은 추가 학습으로 weight 가 바뀌며, 특정 태스크에 더 잘 맞도록 모델을 조정한다.
22. 정답 1 | PEFT 는 큰 모델의 일부 작은 구성만 학습해 비용을 줄이려는 접근이다.
23. 정답 1 | Prompt design 은 모델은 고정된 채 사람이 입력 표현을 조정하는 방식이다.
24. 정답 1 | Prompt tuning 은 학습 가능한 virtual token 을 추가하고 그 임베딩만 역전파로 최적화하는 PEFT 방식이다.
25. 정답 1 | Adapter 는 기존 모델을 크게 건드리지 않고 작은 학습 모듈을 추가해 적응시키는 방법이다.
26. 정답 1 | Teacher 의 지식을 Student 가 모방하도록 학습해 더 가볍고 빠른 모델을 만든다.
27. 정답 1 | Teacher 의 확률분포는 클래스 간 상대 관계를 담아 Student 학습 신호로 활용된다.
28. 정답 1 | SAM 은 범용 이미지 segmentation 모델로 사용자 입력에 따라 객체/영역 마스크를 만들 수 있다.
29. 정답 1 | Grounding DINO 는 자연어로 찾을 객체를 지정해 open-vocabulary detection 을 수행하는 모델로 소개된다.
30. 정답 1 | 교안은 제조업 이미지의 anomaly detection 과 챗봇 형태의 결함 질의응답 활용을 소개한다.

출제 근거: 사용자가 제공한 1-1 AI&기계학습 기초, 1-2 AI&기계학습 방법, 2-1 자연어 처리 기본, 2-2 텍스트 파운데이션 모델, 3-1 딥러닝&영상모델, 3-2 이미지 파운데이션 모델 교안.